

TeXlate 评测体系与指标演化全景报告

七臂评测套件 · corpus_v3 全量综合测试 · 2026-09-19

texlate bench 工作组

2026 年 9 月 19 日

摘要

本文是 TeXlate 评测体系的全景报告：上半部分为不熟悉项目的读者提供背景（管线架构、为什么 arXiv LaTeX 翻译难、评测套件设计与评测现场布局），下半部分是数据——全部历史 commit 考古出的指标演化时间线、2026-09-19 在 corpus_v3 全量 13,266 篇上的综合测试画像、失败归因图谱与已知缺口，以及十条 takeaway。全部数字可追溯：每个指标注明口径与样本框；文档自包含——全部原始数据在随档 `data/`，引用源文档快照在随档 `refs/`，不依赖本目录以外的路径。

目录

1	背景知识	3
1.1	这个项目做什么	3
1.2	为什么这件事难	3
1.3	管线架构	3
1.4	术语与口径	3
2	评测体系设计	5
2.1	七臂总览	5
2.2	评测现场：bench/ 的构成	5
2.3	语料分层构造	6
2.4	逐臂详解	8
2.4.1	B1 parsebench ——解析正确性	8
2.4.2	B2 fixtures ——机制断言集	9
2.4.3	B3 compilebench ——编译与修复循环救回	9
2.4.4	B4 xlatbench / qualbench ——翻译契约与质量	9
2.4.5	B5 e2ebench ——全链组合	10
2.4.6	B6 validbench ——校验器自检	10
2.4.7	B7 alignbench ——锚点保留	10
2.4.8	辅助件	11
2.5	门槛体系	11

3 指标演化史	11
3.1 开发节奏：六天 1,648 个 commit	11
3.2 编译健康度	12
3.3 解析侧：一致率守住，泄漏四天内归零再现身	12
3.4 翻译侧：硬契约与质量评分	15
3.5 评测资产与代码规模	15
3.6 归因表：哪些改动搬动了哪些指标	15
4 2026-09-19 全量画像	15
4.1 全链漏斗：stagerun 五段流水线	15
4.2 翻译质量：qualbench ESA 评分	16
4.3 编译臂：裸编译 vs 中文链条件	16
4.4 翻译硬契约：xlatbench	16
4.5 端到端全链：模拟与真实双臂	17
5 失败归因图谱	17
5.1 解析侧失败面	17
5.2 编译侧失败类	17
5.3 翻译侧失败类	18
5.4 门槛未过项与已知缺口	19
6 Takeaways	19
A 口径与数据说明	20
A.1 统计口径纪律	20
A.2 随档清单与原始产物索引	20
A.3 过程事故记录（评测工具链教训）	21

1 背景知识

1.1 这个项目做什么

TeXlate 是「幻觉翻译」(hjfy.top) 的开源复刻：输入一篇 arXiv 论文的 LaTeX 源包，输出一份重编译的中文 PDF，正文逐段替换为中文译文、数学公式/图表/参考文献结构原样保留，并提供双语对照阅读。链路上的每一段都由自研组件构成：

- **获取层**：arXiv 源包批量下载（IA 批量档 / export / OAI-PMH 三通道），钉版入库；
- **解析层**：自研半解析器——不是完整 TeX 引擎，而是「逐字符扫描 → 切片段 → 占位符保护 → 区间回填」的保真切分器，外加宏展开机（Gullet）把用户自定义宏就地展开；
- **翻译层**：段落级译段经 LLM 网关批量翻译（swe-2 系列模型），占位符协议保护公式与命令不被译文污染；
- **校验层**：L0/L1/L2 三层校验（译段不变量、tree-sitter 结构校验、LLM 评审）；
- **编译层**：ctex 注入 + 规范化 + xelatex/tectonic 双引擎编译；
- **修复层**：修复循环（fixloop）——143 条 YAML 规则驱动（装包、改源、路由、polyfill），把编译失败的论文迭代救回；
- **对齐层**：PDF 具名锚点同步，滚动阅读时中英逐段对齐。

1.2 为什么这件事难

arXiv 源码是脏的真实世界数据。语料横跨 LaTeX2.09 (1990s) 到 2026 年：混用 plain T_EX 原语与 LaTeX2.09 旧式、非 UTF-8 编码 (Big5/GBK/Latin-1)、缺文件的残缺包、tar/gz 双格式、古早宏包 (revtex4、aastex、psfig)。基线实测：裸编译（不做任何修复）能出 PDF 的仅 65–72%，纯净出 PDF 的只有 22–40%——三分之二的论文源码直接编译不出 PDF，最大失败类是缺文件（占裸编译失败的 92.1%）。

宏展开是现成解析器的共同盲区。95% 的论文含自定义宏（中位 47 个/篇，最多 446），其中 12/39 篇手挑语料存在「宏体里藏 \begin/\end」的结构性陷阱，49% 的宏体藏 > 20 字母的可译文本。对 8 个第三方解析库 (latex-utensils、unified-latex、tree-sitter-latex、TexSoup、plasTeX、pylatexenc、LaTeX.js、ieeA) 的横评（原始报告随档 refs/）表明：陷阱断言全军覆没——最好成绩 24/26 vs 自研半解析器 32/32；「能解析」不等于「解析对」，pylatexenc 报 90/90 成功却是静默截断零报错。**无错误信号比崩溃更危险**，这决定了主解析器必须自研、校验器必须独立。

翻译约束是结构性的。译段边界纪律要求公式、命令、环境标签逐字节保留，译文只能在散文区间替换；术语表一致性、学术语域、不可译段（参考文献/版权行）都要显式协议。编译侧中文需要 ctex 注入与 CJK 字体路由，修复侧要处理 EPS 图源、缺 sty/cls、文献链路断点等 ~260 类已建档机制。

1.3 管线架构

图 1 给出全链架构与各段的 benchmark 对应关系。

1.4 术语与口径

后文所有指标沿用本节口径；遇到生词先查此表。




图 1: TeXlate 管线架构与评测臂对应关系。主流流水线自左向右；修复循环是编译段的自动修复回环；B1-B7 为七个评测臂（虚线框），另有 fixtures 陷阱断言集做解析段单元级测试。

- **格 (cell)**: 语料库中一篇论文的存储单元，目录为 `{id}/{meta.json, raw.*, extracted/}`；评测语境下也指一个被评对象（论文 × 引擎组合）。
- **层 (layer)**: corpus_v3 的抽样分层（见 §2.3），每层独立清单、独立抽样框。**EVAL_ONLY** 层为评测专用，开发期采样一律经 `dev_layers()` 排除。
- **臂 (arm)**: 同一被测对象的不同处理条件——编译臂分裸编译（base）与中文链（zh，产品链规范化 +ctex 注入后）；端到端/翻译臂分模拟（mock，确定性假翻译、零成本可复现）与真实（real，真 LLM 网关）；批量驱动的 base 为归因对照臂。编译条件记号：pipe-xel = 产品链后 xelatex 编译，pipe-fix = 修复循环后再编。
- **译段 (chunk) 与片段 (piece)**: piece 为解析器输出的最小片段（散文/公式/命令等类型）；chunk 为翻译最小单位（段落级，由 piece 聚合而来），本批语料译段均长 211 字符。
- **合平 (flatten)**: 多文件论文（`\input/\include` 树）合并为单一.tex 的预处理；孤儿 tex 为不被主文档引用的附属文件（随附 preamble/poster 件），不计入合平覆盖。
- **回填 (splice) 与回填残留**: 把译文按占位符区间替换回源文骨架的重建步骤；回填残留 = 重建后仍残留的占位符数，正常应为 0。
- **纯净 (clean) / 带瑕 (pdf~) / 失败 (FAIL)**: 编译终态三级——纯净 = 无告警出 PDF；带瑕 = 带可接受瑕疵出 PDF（落盘记录记作 partial）；失败 = 无 PDF。**出 PDF 率 = 纯净 + 带瑕**。
- **联合口径 (union)**: 计分卡的出 PDF 统计是「阶段并集」——每格取编译与修复循环两段的较优终态；与之相对的终末口径只看最末段状态。base 臂是归因基线，不计入联合。
- **逐字节一致率 (identity) 与泄漏 (leak)**: 解析质量两轴——一致率为重建后逐字节相符的文件占比；泄漏为受保护内容（公式/命令）误入可译译段的占比。
- **死占位符 (dead ph) 与孤儿译段 (orphan)**: 解析侧两类零容缺——占位符未被任何译段消费称死占位符；译文译段找不到回填位置称孤儿。
- **批量驱动 (stagerun) 与计分卡 (scorecard)**: stagerun 为五段批量驱动（获取 → 解析 → 翻译 → 编译 → 修复，逐格追加式落盘 records）；scorecard 为 gate_scorecard 对记录的终态统计，M2 出口门出 PDF 率 ≥ 90%、纯净率 ≥ 90%。
- **硬契约 (hard_ok) 与契约族**: 翻译臂的硬契约判定——占位符全还原（ph_missing、ph_invented）、控制序列保留（cs_dropped）、结构校验通过（validator_ok）。顺序类分硬换序（ord_hard，破契约）与软换序（ord_soft，合法中文换序告警，不计败）。

- **ESA 评审与争议判例 (contested)**: 质量臂的 LLM 评审协议——评审模型按 ESA 错误分类打 0–100 分；初裁与复核分歧的判例记为争议，由第二评审仲裁。
- **具名锚点 (named-dest)**: PDF 具名锚点 (`hyperref \label` 位点)；对齐臂测双版锚点保留率实现逐段对齐。
- **修复循环 (fixloop) / 机制 (mechanism) / 车道**: `fixloop` 为 YAML 规则驱动的编译修复循环；`mechanism` 为机制台账 (`mechanisms.jsonl`, 快照随档 `refs/`) 登记的已知缺陷模式 (`dollar` 族泄漏、`eps_route` 等), 是「benchmark 发现 → 归因 → 规则沉淀」反馈环的载体；车道/波次为多代理并行修一批同族缺陷的工作单元；**自改进环 (selfimp)** 为 09-18 起常驻的多代理改进环 (车队台账快照随档 `refs/`)。
- **v2 切换 (cutover)**: 09-16 解析主路径从 v1 逐字符扫描器切到 v2 展开机 + 切分器的事件, 切换硬门为回填残留占位符清零。
- **批量档 (bg)**: 网关批量档——低优先级队列, 入闸排队约 120 秒, 评测批跑默认档位, 延迟读数含排队时间。

2 评测体系设计

2.1 七臂总览

评测套件按「每臂对准管线一段 + 一个组合层」设计：每条臂独立成 harness，产出机读落盘记录供计分卡与归因消费。评测器规格冻结件随档于 `refs/` (`10-benchmark-suite.md`)，共同底材为 `corpus_v3`。表 1 为总览。

表 1: 七臂评测总览 (B1–B7 + 辅助件)

#	评测臂	测哪段	底材	核心指标
B1	<code>parsebench</code>	解析段	<code>corpus_v3</code> + <code>corpus39</code>	解析成功/一致率/泄漏/死件/合平
B2	<code>fixtures</code>	解析段 (单元级)	手构陷阱 <code>.tex</code> 集 (10 件)	陷阱断言通过率 (T01–T98)
B3	<code>compilebench</code>	编译段 + 修复循环	<code>corpus_v3</code> 原始包	纯净/带瑕/失败、救回率、规则谱
B4	<code>xlatbench</code>	翻译段	<code>corpus_v3</code> 译段抽样	硬契约率 / 延迟 / token 经济
B4b	<code>qualbench</code>	翻译质量	e2e 产物段对	LLM 评审 ESA 评分 / 缺陷分类
B5	<code>e2ebench</code>	全链 (组合)	<code>corpus_v3</code> 子集	逐段漏斗 + 终态分布 + 引入回归
B6	<code>validbench</code>	校验段	合成破坏案例	检出率 / 误报 / 延迟
B7	<code>alignbench</code>	阅读体验	中英编译产物对	具名锚点保留率 / 链权

辅助件: `stagerun` (五段批量流水线)、`gullet_bench` (展开机实测)、`gate_scorecard` (M2 出口门)、`translators_bench` (模拟臂工厂)、`nightwatch`

依赖序: `corpus_v3` → B1 → B4 → {B3, B5} → B7; B2/B6 以合成输入独立。

2.2 评测现场: `bench/` 的构成

所有评测资产集中在仓库 `bench/` 树, 入口文档为 `PROTOCOL.md` (逐库横评协议) 与 `TIERS.md` (验证分层契约, 均随档 `refs/`)。后者定义「一个问题该在哪一级被抓住」: L0 单测/断言样例 (秒

级, CI 硬门) → L1 语料机制覆盖 (分钟级) → L2 stagerun 子集回归 (分钟到小时, 机制台账定向重放) → L3 全层全臂过夜集成 (里程碑门); 规则是「能低不高」——低层能钉住的问题不许只在批量上撞见, 批量发现的真坑要沉淀回 L0 层断言。本报告 B1–B7 属 L1–L3 层读数。布局与职能:

表 2: bench/ 现场布局 (不熟悉仓库的读者对照此表读结果目录名)

路径	内容
bench/py/	37 个评测脚本, 分四簇—— 批量驱动 : stagerun.py + stage_{ingest,parse,xlat,compile,fixloop} (五段流水线, 落盘记录逐格追加式写入); 七臂评测驱动 : parsebench、compilebench_v3、xlatbench、qualbench、e2e_mock_bench、e2e_real_bench、fixloop_bench、alignbench、validbench、gullet_bench、fixture_assert; 门禁监控 : gate_scorecard (M2 出口门)、status_panel、nightwatch、rundiff、triage、wave、stage_timing; 支撑件 : benchlib 公共库、translators_bench (模拟译文工厂)、corpus/ 语料构建管线、iclr_* 对照语料渠、report/ 一次性审计、scratch/ 一次性探针
bench/ts/	JS 侧三库横评驱动 (latex-utensils/unified-latex/tree-sitter-latex), D0 选型证据产地
bench/corpus*	语料族: corpus 39 篇手挑陷阱、corpus_v2 139 篇分层、corpus_v3 13,266 篇八层钉版 (§2.3)、corpus_daily RSS 日更渠 (~1,200 篇/日)、corpus_iclr* ICLR 对照渠
bench/fixtures/	10 件手构陷阱 .tex (@Tnn/@Wnn/@Xn 断言标记: T 为结构陷阱、W 为野外发现机制、X 为翻译层; 逐字节即语义, 不做任何格式化)
bench/results/	评测产物区: 每次运行一个日期目录 (377+ 轮累积), 含 records/summary/jsonl/PDF 中间件; 大体量不入档, 本报告读数全部由其抽取进 data/
bench/work_*/	编译/fixloop 逐格工作区 (解压源树、aux、PDF; 重产物 gitignored)

2.3 语料分层构造

corpus_v3 是钉版批量语料: 每格记录 (channel, item, member, blob_sha256) 四元组钉住字节级来源 (resolved_version=null), 落地为 {id}/ 目录 (meta.json、raw.*、extracted/)。四条渠道各有明确分工: ia = IA arxiv-bulk 月度块 (a–d 时代带主力, 覆盖至 2020-10); tiger = HF TIGER-Lab/arxiv-latex-5T (e 带主力, 成员截止 2412 月); arxiv_eprint = 单发源包取源 (走产品 acquire_source, 补 TIGER 截止后 2501+ 盲区); hf_scholarweave = scholarweave 脱水通道 (figures_stripped 有损源——解析/翻译段可用, 编译段因缺图源排除)。全库 13,266 格、原始包 18.8GB (含 extracted/ 解压树全库约 46GB)。八层构成见图 2、分层定位见表 3: 核心/补强/扩展/热层为早期层, 2026-09-19 评测/开发分轨扩层后收至 13,266 篇。

抽样框是「时代带 + 机制旗标带」的二维结构: 五个时代带 a_pre2007 / b_2007_11 / c_2012_16 / d_2017_20 / e_2021_25 各 ~1,700–2,050 篇均匀打底 (时间跨度 1994–2026), 上面




图 2: corpus_v3 八层构成 (13,266 篇, 原始包 18.8GB / 含解压树约 46GB)。holdout 层为 EVAL_ONLY 治理——dev_layers() 实测排除, 仅评测可读; dev_* 三层与 expand 为开发期增量; core 为月度簇分层随机 (30 簇, old 200/new 800)。

表 3: corpus_v3 八层定位与抽样框 (渠道缩写: ia=IA 月块 / tiger=HF arxiv-latex-5T / eprint= 单发取源 / sw=scholarweave 脱水)

层	篇数	定位	渠道构成与抽样框
core	1,000	核心随机层, 评测主干	ia 800 + tiger 200; 30 个 IA 月簇分层随机 (old 200 / new 800)
booster	200	机制策展层	ia 162 + tiger 38; 野外发现机制提名制 (107/109 W exemplars, nominations/留审计轨迹)
expand	3,866	体量扩展层	ia 3,103 + tiger 697 + eprint 66; bulk 池 measure-then-sample
hot	166	近期高引层	arxiv_eprint 166; OpenAlex 高引近期, 专打 2501+ 盲区
dev_vol	2,000	开发体量层	ia 1,627 + tiger 373; 3,671 tex · 2.76GB
dev_recent	1,514	近期开发层	sw 1,065 + eprint 449; TIGER 截止后盲区双通道
dev_failmine	1,500	机制挖掘层	ia 1,500; FLAG_RX 机制旗标定向挖 IA 94–15 年档陷阱
holdout	3,020	留出评测层	ia 2,159 + tiger 540 + eprint 321; EVAL_ONLY, 同构造规则独立抽样

叠机制旗标带定向覆盖已知陷阱族 (flag:deadpkg 600、flag:docstyle209 300、flag:epsfig、flag:babel、flag:pdftex、flag:pstricks 等若干) 与 swlyymm 月度带 1,065。学科面随 arXiv 主力盘分布 (图 3 左): hep-physics 2,961、math 2,418、cs 2,393、astro-ph 1,826、cond-mat 1,729 为五大盘。

物理形态与工程结构: tar 包 11,097、gz 单文件 2,144、single_gz 12、stub 13 (B07 有意构造的残缺件); 单篇文件数中位 7 / p90 28 / 最大 3,047 (一篇论文三千文件), .tex 均 2.2 个, 多文件工程 2,115 篇 (16%) ——合平与多文档路由不是边角料而是主场景之一。许可面: arxiv-nonexclusive 6,786、missing 3,335、CC 系合计 1,187。全库 70 个聚簇键 (cluster_id, 月簇/渠道混合) 支撑簇稳健自举; 4,472 格带 B01-B07/W/T 机制标签——即「评测发现 → 归因 → 策展回填」反馈环的载体。




图 3: corpus_v3 构成两视图。左: 学科组分布 top8 (其余 470 篇未绘); 右: stratum 带分布——a-e 五时代带共 9,565 篇均匀打底, sw 月带 1,065, flag 机制带/dev 补/holdout recent 等合计 2,636。

治理规则: holdout 层 (3,020 篇) 登记 EVAL_ONLY_LAYERS, 所有开发期采样经 dev_layers() 过滤; 语料扩展只加层不删层; 格数据不入库 (gitignored), 入库物为清单八件与选样报告 (selection_report.md); 机制台账 mechanisms.jsonl、B04/B06 宇宙 × 语料覆盖簿记 eval_coverage.json、补强层提名审计轨迹 nominations/ 的快照均随档 refs/——台账是「评测发现 → 归因 → 规则沉淀」反馈环的载体。

2.4 逐臂详解

2.4.1 B1 parsebench ——解析正确性

测什么: texlate.latex 半解析器在真实语料上的正确性——能不能零崩溃跑完、能不能逐字节还原、可译译段里有没有漏进受保护内容。

怎么测: 逐文件 30 秒超时, 先定位主文件, 再做多文件合平, 随后调用解析器, 最后跑重建三连测——逐字节一致 (strict identity)、空译文假翻译 (fake-translate, 注入死占位符/孤儿探针)、占位译文 (泄漏探针)。逐文件结果写入 files.jsonl, 逐篇聚合成 papers.json, 同时产出路由标签 (reject / xelatex / minted / non-utf8 / no-hyperref——这组标签同时充当 B3 的静态路由金标准) 以及合平覆盖率、多文档/无根标记。统计口径为核心层加权池化率与宏平均双报, 置信区间用 Wilson 加月簇稳健自举; 另有 oracle 对拍探针 (plasTeX 规范化文本流对译段的字符级召回), 仅作开发期召回探针、不进门槛。所有异常逐条人工归因后写回机制台账。

当前读数：28,904 文件解析成功率 100.0%、逐字节一致率 99.99%、泄漏率 0.004%（图 6、表 6）。

2.4.2 B2 fixtures ——机制断言集

测什么：parsebench 测分布，断言集测机制——「这个具体的坑处理了吗」逐条断言。

底材：10 件手构 .tex (tricky 主集 + 209 旧格式件 + multi 多文件工程件 + w/w73/wenc 野外机制件 + xlat-traps 翻译层件)，@Tnn（结构陷阱）/@Wnn（野外发现机制）/@Xn（翻译层）三族标记；**逐字节即语义**，永不格式化。**生长机制：**parsebench 归因与台账中 found-in-wild 条目达到 covered 状态后提取固化为断言样例——语料里每个真坑沉淀为一条永久断言，断言面只增不减。

当前读数：98 条断言 pytest 全绿（L0 层 CI 硬门，断言函数与 fixture_assert.py 共享）；BUG1 占位符尾回归断言实测为 0。

2.4.3 B3 compilebench ——编译与修复循环救回

测什么：规范化 + ctex 注入 + 引擎 + 修复循环的真实救回能力——hjfy 约五千篇人肉沉淀护城河的对物。

怎么测：论文 × 条件 × 引擎三维网格——条件取原文裸编 (base) / 中文注入 (zh) / 模拟译文 (mock) 三种，引擎取 xelatex 与 tectonic 两种；编译前先做路由预检 (documentstyle → 直接拒编、eps/pstricks → xelatex、minted-frozenecache → tectonic)。每格走「规范化 → 中文注入 → 沙箱编译（至多 2 轮、240 秒限时）→ 修复循环 → 纯净判定三件套」；逐格判定 (verdict) 连同每轮 {cat, pay, rule, result} 动作落盘，直接灌回机制台账。失败归因按首错签名聚类 (verdict_sig 口径：当构成中计数最高的错误类超过首错类时改挂该众数类)。指标：纯净率（分条件/引擎/时代带）、失败 → 出 PDF 救回率、规则触发/救回数、卡死率、修复轮数分布。

门槛：200 篇中文链条件编译成功率 ≥ 90% (hjfy 的 95% 为渐近线)、拒编判定正确率 100%（与路由标签对拍）、无回归（原本纯净的格不被规则改脏）。

当前读数：500 格联合口径出 PDF 90.4%（图 11）；中文臂 xelatex 纯净率 +16.1 个百分点——规范化顺带修复源缺陷，产品链成本转正收益。

2.4.4 B4 xlatbench / qualbench ——翻译契约与质量

B4a 硬契约层：译段 × 模型 × 重复次数网格，译段按类型分层抽样（正文段、图题、条目、脚注，外加压力样例——\bibitem 前缀、\href 等陷阱位）；每个响应过 L0 校验器，指标按序读——硬契约通过率（丢/造占位符、丢脆弱命令、校验错误）→ 换序软信号（合法中文换序不降权）→ 延迟 → 推理量 → token 经济。用途是模型选型与白名单刷新（免费集推广期到期即重跑）以及提示词措辞回归（每次提升 prompt_version 必跑）。

B4b qualbench 质量层：LLM 评审 (esa2 协议) 逐段对打 0–100 分，并按错误分类 × 严重程度三级打标（术语/流畅/准确/约定/漏译五族九类）；初裁 swe-2-max，分歧判例记为争议，由 swe-2-high 复核仲裁；产出均分/中位分、分数段分布、按译段类型与按论文的细分。门槛 M1：100 篇真实翻译端到端 ≥ 85%。

当前读数：硬契约通过率 93.7% (254/271)、ESA 均分 94.0 / 争议率 5.5%（图 10）。

2.4.5 B5 e2ebench ——全链组合

测什么：单段绿不等于组合绿——逐环节成功率漏斗加终态分布。四模式：**Mode A** 位置忠实的模拟译文（用占位译文走全链验证机械链路：能否出 PDF、逐字节一致、零残留占位符；已知盲区是模拟翻译只认 ASCII 散文段，非 ASCII 散文会原样回显、过估忠实度——真实翻译臂不受影响）；**Mode B** 幻觉模拟（注入占位符丢失/幻觉破坏，验证校验链兜底——132 处破坏编译前 132/132 捕获，「出 PDF ≠ 成功」的实证来源）；**Mode C** 位置扰动模拟（随机移动约 10% 占位符，量化回填鲁棒性）；**Mode D** 真实翻译接入（产品 SLA 观测点）。另有 **pipe-fix 救回臂**：把 pipe-xel 的产物树送进修复循环复判，联合口径取两臂较优者；**onfail** 语义经冒烟校准为「失败 + misschar/error 级带瑕」才救（带瑕已出 PDF，引擎重跑只会丢 PDF 救不了告警），注入拒编不救。

当前读数：模拟臂管线 xel 33/39 纯净 vs 裸编 19/39（管线净正 +14 格）；真实臂 60 篇联合口径出 PDF 96.7%、回填残留 0、0 管线引入回归。

2.4.6 B6 validbench ——校验器自检

测什么：L0/L1 校验器对 LLM 破坏的检出能力——校验器本身必须被评测（实现期真抓到过校验器自身 bug）。

怎么测：变异器对干净译段施加 10 类破坏（丢右括号、丢美元符、\end 改名或删除、丢/拼错/凭空多占位符、\[不配对、幻觉宏、删引用键），在占位符层/原文层两层生成 cases.jsonl；另加对抗性手工探针（丢 \emph 组、占位符合法换序、\cite {k} 带空格、漏引用键、全角占位符等——验证合法改写不误报）。指标：检出率（按破坏类分列命中规则）、干净对误报率、仅告警率、每对延迟、编辑距离 ≤2 修复建议率；L1 tree-sitter 层同口径。B4 产出的真实失败案例反向喂回 B6，沉淀为新破坏类。

门槛：10 类破坏 100% 检出、干净对 0 误报、L0 ≤1ms/对。

当前读数：corpus_v2 1,503 对全绿（摊薄 0.374ms/对）——本批未重跑，列缺口清单第 7 项。

2.4.7 B7 alignbench ——锚点保留

测什么：中文重编译后 PDF 具名锚点（named-destination）保留率——双语滚动同步的质量上限。

怎么测：用 pypdf 提取中英两侧具名锚点，同名锚点配对，计算保留率与最大权值单调链权重（节标题锚权 12、图锚 10、公式锚 4、引用锚 2，page.* 页锚权 0）。未用 hyperref 的工程（语料中约 31%）走退化路径、只断言不崩溃；**保留率 <95% 本身可当中文编译完整性探针**（ctex 共享计数器改 theorem 锚名的问题即由此捕获）。

门槛：有 hyperref 对保留率 ≥95%；无 hyperref 对退化路径不崩。

当前读数：812 对门全过但覆盖薄——765 对无具名锚点，有效读数仅 42 个 hyperref 对（保留率中位 1.0），口径待复核（缺口清单第 3 项）。

2.4.8 辅助件

stagerun 五段批量流水线（逐格追加式落盘、按 (id,arm,upstream) 断点续跑、网关信号量限流），配 gate_scorecard 做 M2 出口门（联合口径 = 编译 $\cup$ 修复两段逐格取优）；translators_bench 为模拟臂译文工厂（忠实模拟 / 注入破坏 b、c / 位置扰动）；gullet_bench 为展开机实测（200 篇全展开中位 39.6ms/19 步）；另有 triage（落盘记录 $\rightarrow$ 问题工单聚类）、status_panel、nightwatch、rundiff、wave、stage_timing、preflight_batch 等监控与批前闸件。

2.5 门槛体系

各臂门槛（语料规格 §8，随档 refs/）：parsebench——解析成功率 100%、逐字节一致率 $\geq 99.5\%$ 、泄漏率 $\leq 0.15\%$ 、死占位符与孤儿译段 = 0、合平覆盖率 $\geq 99\%$ ；M2 出口门（stagerun 计分卡）——联合口径出 PDF 率 $\geq 90\%$ 、纯净率 $\geq 90\%$ 。统计口径：核心层加权池化率 + 宏平均双报，置信区间用 Wilson 加月簇稳健自举。

3 指标演化史

本节数据来自三路考古：全部 1,648 条历史 commit 逐条扫描（里程碑识别）、评测结果流水 377 个日期目录的读数回填、车队台账与上一期复盘（口径锚点）。本文档自包含：原始数据入库于随档 data/ 子目录（scorecard/parse/corpus/rules-tests/qual-xlat 五条时间线 CSV + 377 行评测活动流水含各轮 run 目录名 + 1,648 行 commit 全录 + milestones.md），引用源文档时点快照在随档 refs/（台账、复盘、评测器与语料规格、8 库横评报告、机制台账）；口径不一的读数分线绘制并注明样本框。

3.1 开发节奏：六天 1,648 个 commit




图 4: commit 日吞吐（累计 1,648）。09-17 峰值 624 对应「波次战」（离线宏包 shim/illegal_unit/段修多车道并行收割）；全程为多代理车队协作模式（监督台账记名册峰值约 23 车道），commit 由主会话统一落盘。

项目节奏呈「日主题」结构（图 4、表 4）：D0 立项与八库横评定案、D1 产品骨架（七臂同日落地）、D2 v2 切换 + 修复循环接线（最大单日指标跃升）、D3 波次战收割残面、D4 自改进常驻环、D5 语料收官 + 全量综合测试。

表 4: 六日大事记 (commit 考古, 精选)

日	主题	标志事件
D0 09-14	立项定案	仓库初始化; 8 库横评 (39 篇 + 30 断言样例) —— miniscanner 陷阱 32/32、逐字节一致 259/259 定案自研路线; 技术栈选型冻结
D1 09-15	产品骨架	miniscanner 重写为 <code>texlate/latex</code> 九文件; Mouth+Gullet 展开机; 编译/翻译/服务端/阅读器全套; 七臂同日落地 ; 修复循环 25 条规则移植; 语料 →1,339
D2 09-16	切换 + 接线	v2 切换 (回填残留 1524→0); 修复循环接线 (出 PDF +18.9pt); expand+hot 层语料 →5,410; loop1 $n=5124$ 计分卡 97.89%; qualbench 诞生
D3 09-17	波次战	离线宏包 23 件翻 492 格; <code>illegal_unit</code> 族 108 闭环; ReDoS 修复 pytest 48min→3:46; 翻译层 P0 封死错配通道; realn200 98.5% 真臂验收
D4 09-18	自改进环	常驻改进环 23 车道发车; loop2 97.26%/86.42%; dollar 族泄漏清零 ; qualbase 92.9 建档; corpus_daily 日更渠启动
D5 09-19	收官 + 全量	corpus_v3 八层 13,266 篇 (开发/评测分治); 完整性审计全绿; 12 臂综合测试同日落地 (本报告主体); loop3 在飞

3.2 编译健康度

三条叙事线(图 5): **修复循环是单一最大杠杆**——09-16 接产品链当日联合口径出 PDF +18.9 个百分点 (70.6→89.5, 同 180 篇复跑); **波次战把残面打成个位数**——离线宏包波翻 492 格失败面、`illegal_unit` 族 108/108 闭环、计分卡一波 89.17→97.89; **真实臂与模拟臂打平**——realn200 联合出 PDF 98.5% 证明评测面非虚高, 今日 e2e-v3b 终态 96.7% (7 个管线失败格全被修复循环救回、2 格超大工程跳过)。未达标项只剩 M2 纯净率 $\geq 90\%$ (今 88.75%, 差 1.25 个百分点)。

3.3 解析侧：一致率守住，泄漏四天内归零再现身

解析侧四天稳态 (图 6): v2 展开机 + 切分器切换当日回填残留占位符 1524→0; 泄漏残留清一色 dollar 族, 09-18 单类收口归零——但归零是在 **1,955 文件核心层**上, 今日 8 倍体量全量复测重现 76 条命中, 说明该族机制在长尾语料上未穷举, 属于「已识别族的覆盖率问题」而非新机制。




图 5: 编译健康度时间线。计分卡线为 stagerun 落盘记录在代码演进下的重评 (loop1 $n=5124 \rightarrow$ loop2 $n=5219 \rightarrow$ v3all 样本 $n=80$); 真实臂为真 LLM 翻译全链 (realn200 $\rightarrow$ e2e-v3b $n=60$ 终态); 方块为裸编译基线——注意基线自身四天涨约 19 个百分点 (71.7 $\rightarrow$ 90.2): 离线宏包资产 + tlmgr usertree 积累使工具链整体成熟,「裸引擎撑死七成」的 09-15 结论已不适用今日地板。




图 6: 解析侧演化。左: 漏洞命中数——dollar 族 58/57 条残留于 09-18 c2-dollar 车道清零 (核心层口径), 09-19 全量 28,904 文件上重现 76 条 (1,845,338 译段中占 0.004%, 新语料表面新案例, 非回归)。右: 逐字节一致率全测量期 $\geq 99.99\%$ (纵轴截断)。




图 7: 翻译侧演化。左: swe-2-medium 硬契约率——09-15 冒烟期网关不稳 (http_err 17) 压到 64.6%, 契约批 98.8%, 今日全层抽样 93.7% (新校验口径 v_err 27 条计入后更严); 右: ESA 评审均分 92.9 $\rightarrow$ 94.0 (swe-2-max 初裁, 争议率 8.1% $\rightarrow$ 5.5% 下降)。




图 8: 资产增长 (git 历史抽样, 同日口径一致): pytest 用例 798→6,450、修复规则 31→143 (16 分片)、源码 72→425 文件、语料 corpus39/v2 → v3 八层 13,266 (另有 corpus_daily 日更渠约 1,200 篇/日在库外增长)。

表 5: 改动 → 指标位移归因 (commit 级, 摘自台账与各波报告)

日期	改动 (commit)	指标位移
09-14	8 库横评 + miniscanner 探针	主解析器路线定案 (陷阱 32/32, 逐字节一致 259/259)
09-15	corpus_v3 core+booster + 双引擎基线	基线口径建立 (联合出 PDF 71.7%/纯净 39.4%, 180 篇)
09-15	修复循环 yaml 引擎落地 (179f7e5b)	25 条规则移植, 修复臂诞生
09-16	修复循环接产品链 (3d5de8f7)	联合出 PDF 70.6→89.5% (+18.9pt, 同口径复跑)
09-16	v2 展开机 + 切分器切换 (f4616838)	回填残留占位符 1524→0 (切换硬门)
09-16	argspec.json 入包 (401e9bbf)	1820 条宏参规格零装载缺口闭合
09-16	perf-tail 五修	解析长尾 -48% (51476→26723ms), 一致率零回退
09-16	stagerun loop1 全流水线 (n=5124)	计分卡 97.89%/84.99%; 修复救回 84.0%
09-17	vendored_fetch 离线宏包 23 件 (a90978ab)	绝版宏包缺件面 492 格失败 →73.2% 纯净, 纯净 +101 格
09-17	illegal_unit 段修波 (d2c377bd)	108/108 闭环零回归, 纯净率 84.76→85.03%
09-17	ReDoS 原子组修复 (746237fd)	held6 卡死 30min+→0.1s; pytest 全量 48min→3:46
09-17	非锚定 [n] 译文解析撤除 (164a9e0f, P0)	译文静默错配通道封死, 同批核销 4 个 P1
09-17	realn200 真臂验收 (f2847c33)	联合出 PDF 197/200=98.5%, 与模拟臂打平
09-18	c2-dollar 车道收口	泄漏 57→0/136,049 译段 (核心层口径单类清零)
09-18	gate_scorecard schema v3	loop1 复跑 97.89/84.99 分毫不差——评测器自证稳定
09-18	qualbase esa2 (n=1200)	质量基线建档均分 92.9 [92.4,93.3], 争议率 8.1%
09-18	loop2 冻结快照 (n=5219)	计分卡 97.26%/86.42% (纯净率 +1.43pt)
09-19	corpus 8 层扩层 (13c603cf)	语料 5232→13,266, EVAL_ONLY 治理落地
09-19	全量综合测试 (本报告)	12 臂同日落地; 基线地板升至 90.2%; stagerun 98.75%/88.75%

3.4 翻译侧：硬契约与质量评分

3.5 评测资产与代码规模

3.6 归因表：哪些改动搬动了哪些指标

4 2026-09-19 全量画像

本节为 corpus_v3 扩充收官（13,266 篇）后的首轮全量综合测试，12 个评测臂同日落地。总表见表 6，逐节展开关键分布。

表 6: 2026-09-19 综合测试逐臂指标总表

臂	规模	核心指标	门槛对比
完整性审计	13,266 格	sha256 13,266/13,266, 0 重复、0 缺失; 13 个 stub 为 B07 有意构造	EVAL_ONLY 生效
parsebench	13,253 篇 / 28,904 .tex	解析成功 100.0% ; 一致率 99.99% ; 泄漏 0.004% (76/1,845,338); expand 层足迹 strict 28105/norm 259/div 539; 合平 93.7%	一致率/泄漏过门; 死占位符 =3 未过; 合平未过
compilebench 裸编	500 格 ×2	xelatex 纯净 56.3%/出 PDF 80.3%; tectonic 38.6%/62.4%; 联合出 PDF 90.4%	—
compilebench 中文链	500 格	xelatex 72.4%/85.4% (纯净 +16pt); tectonic 45.7%/59.8%	—
修复循环 (v2 40)	80 格	xelatex 34 格失败 → 25 救回 74% ; tectonic 1/16 (EPS 路由主导)	—
alignbench	812 对	门全过; 765/812 对无具名锚点, 真实覆盖 42 对 (保留率中位 1.0)	覆盖不足
e2e_mock	corpus39	管线 xel 33/39 纯净 vs 裸编 xel 19/39; 引入回归 3	—
e2e_real	n=24+60	58/58 翻译; 译段通过 6053/7580; 回填残留 0 ; 管线 xel 纯净 43/失败 7; 修复循环再救 13; 0 引入回归	—
xlatbench	271 样本	硬契约 93.7% ; http 错误 0; 延迟 p50 4.2s/p95 29.7s	—
qualbench	324 篇/1937 译段	评审均分 94.0 , 中位 95; ≥90 占 90.6%; 争议率 5.5%; critical 1	—
gullet	200 文档	199/200 展开成功; 中位 39.6ms/19 步	—
stagerun 流水线	80 篇跨层	联合出 PDF 79/80=98.75% ; 纯净 71/80=88.75%	M2 出 PDF 门过

4.1 全链漏斗：stagerun 五段流水线

五段批量流水线对 80 篇跨层样本的实测漏斗 (图 9): 获取 80 → 解析 79 通过 (1 拒) → 翻译模拟臂 76 通过 + 3 带瑕 → 编译中文臂 61 纯净 + 13 带瑕 + 5 失败 + 1 跳过 → 修复循环在 21 格上动作 (失败 → 纯净 5、带瑕 → 纯净 5、带瑕保持 8、纯净复核 3)。联合终态 **纯净 71 + 带瑕 8 = 出 PDF 79/80 (98.75%)**, 过 M2 联合出 PDF ≥ 90% 门; 纯净率 88.75% 距 90% 门差 1.25pt。同格对照臂裸编译 (50 纯净 + 19 带瑕 + 10 失败) 给出归因锚点: 管线加修复循环相对裸编译 **出 PDF +10 格 (69→79)、纯净 +21 格 (50→71)**。




图 9: stagerun 五段漏斗与同格对照 (80 篇跨层样本, 翻译上游为模拟臂)。左: 主流流水线中文臂逐段存活数; 右: 同一 80 格上裸编译 vs 中文链 + 修复循环联合终态——管线相对裸编译出 PDF +10 格、纯净 +21 格 (修复循环把 5 格失败全救成纯净、5 格带瑕升纯净)。

4.2 翻译质量: qualbench ESA 评分

swe-2-medium 译文对 324 篇论文 1,937 个译段的 LLM 评审评分 (初裁 swe-2-max, 复核 swe-2-high, 争议率 5.5% 触发复核): 均分 94.0 / 中位 95, ≥ 90 分占 90.6%, critical 级缺陷仅 1 例 (漏译类)。分数段与文类分布见图 10: 节标题最高 (96.9), 图题 93.2, 正文段 92.2——长散文段仍是质量洼地。




图 10: qualbench 评分分布 (左: 分数段; 右: 分类均分)。1,756/1,937 译段 ≥ 90 ; 正文段是主要拉低项 (缺陷榜前四: 术语不一致 229、语法 197、误译 132、幻觉内容 66)。

4.3 编译臂: 裸编译 vs 中文链条件

500 格抽样双引擎对照 (图 11): 中文链条件 (产品链规范化 + ctex 注入后编译) 反而比裸编译高 16pt 纯净率——规范化顺带修复了源文件的编码/格式缺陷。tectonic 在中文臂纯净率升而出 PDF 略降, EPS 图源是其死穴 (见 §5)。

4.4 翻译硬契约: xlatbench

271 个抽样上下文对 swe-2-medium 的硬契约测试: 硬契约通过 254/271=93.7%, http 错误 0。延迟 p50 4.2s / p90 16.2s / p95 29.7s / max 104.4s——批量档入闸排队在长尾可见。token 经济: 输入 77.4k / 输出 40.8k (平均每译段 285/150), 推理量均 93 tok, 提示词缓存命中 0% (抽样源分散)。按类契约率: 压力样例 4/4、正文段 64/67、图题 62/67、条目 61/66、脚注 58/60——脚




图 11: compilebench 500 格: 裸编译 vs 中文链条件。中文臂 xelatex 纯净率 +16.1pt——规范化顺带修复了源级缺陷; 联合出 PDF 90.4% (双引擎取优)。

注/条目类是短板。失败类: `cs_dropped`×8、`ph_miss`×5、`validator`×3、`ord_hard`×1; `ord_soft` 78 条软换序告警 (不破契约, 但提示换序倾向)。

4.5 端到端全链: 模拟与真实双臂

模拟臂 (corpus39): 管线 xel 33/39 纯净 vs 裸编 xel 19/39——管线净正, 翻译 + 回填步骤不损反增 (规范化顺带修复); 3 格引入回归。真实臂 n=60: 58/58 翻译完成, 译段通过 6053/7580 (带瑕 43/故障 8), 回填残留占位符 0 (过门), 管线 xel 纯净 43/失败 7/带瑕 6, 修复循环再救 13 格, 0 管线引入回归。编译失败类: 缺文件 ×7、缺图 ×3、信号终止 ×3、引擎崩溃 ×3——以语料源缺资产为主。

5 失败归因图谱

5.1 解析侧失败面

全量 28,904 文件仅 1 个解析错误 (语料源怪癖: 伪装成 `.tex` 的 tar 包) 与 1 个一致率分叉文件——硬失败面已枯竭, 残面转移为告警谱 (不挡解析但值得跟踪的形态): `stray_end` 3,007、`missing_input` 2,757、`unpaired_dollar` 383、`expand_tail_dropped` 313、`unclosed_env` 223、`def_parse_fail` 140、`cite_range_key` 62、`env_mismatch` 27 等。泄漏 76 条命中构成为 `dollar` 族 75 条 + 引用族 1 条——`dollar` 族长尾未穷举 (演化史见图 6)。

5.2 编译侧失败类

真实臂 n=60 的编译失败归因 (图 12 左): `missing_file`×7 与 `missing_graphic`×3 合计过半——语料源自身缺资产 (arXiv 源包打包不全), 非管线引入; `killed_by_signal`×3 为超时/资源类; `driver_fatal`×3 为引擎级崩溃。

compilebench 500 格裸编译首错归因 (修复循环 F 类命名): xelatex 侧 `missing_file`×94 居首 (代表 `psfig.sty`——古早宏包缺件) > `other`×48 > `driver_fatal`×13; tectonic 侧

ps_image×142 一家独大 (EPS 图源)。路由收益有实证：「eps/pstricks→xel 优先」带 162 篇，xel 出 PDF 90/带瑕 24/失败 47 vs tec 4/22/135；**latex209_suspect** 带 65 篇呈反向互补 (xel 失败 43 vs tec 带瑕 36——古文在 tectonic 下更易出带瑕疵 PDF)，**non_utf8** 带 37 篇。学科面难度分层明显：cs 最易 (xel 出 PDF 83/86)、math 次之 (79/87)、astro-ph 最难 (41/64)。

修复循环救回矩阵 (corpus_v2 40 篇对照)：xelatex 34 个失败格救回 25 (74%)，主力规则为 **install_file** (14 次触发，8 格出 PDF)、**install_tfm** (12 次触发，7 格)、**static_precheck** (40 格全触发)；装包榜首位 **subfigure.sty×10**、**revtex4.cls×9**。tectonic 臂仅救 1/16——**EPS 路由拒编是结构性死穴** (11 格全拒)：EPS 图源在 tectonic/xdvipdfmx 通路无解，唯一出路是路由到 xelatex。另有 **latex209_reject** 闸拦下 LaTeX2.09 古文 8 格 (该类论文需 209→2e 重写通道，非装包可救)。本批 stagerun 中修复循环动作谱更轻量：21 格触发标准三件套全命中 (**tar_blob_extract**、**subfile_docclass_strip**、**static_precheck**)，外加 **missing_char_fix**、**vendored_fetch** 等 10 条各 1–4 次。

5.3 翻译侧失败类

xlatbench 失败类分布 (图 12 右，17 个硬失败全归因)：**cs_dropped×8** 居首——控制序列在译文中丢失，且高度集中为脆弱间距命令 (`\`、`\,`、`~` 被中文熔合吞掉，占 8 中 7 条)；**ph_miss×5** (占位符未还原，其中一格连丢 **CMD_77–CMD_85** 九个占位符——单译段级联性丢失而非均匀散布)、**comment_eof×2** (译文尾段注释未终结吞掉下一行字面量，可致回填后失控)、**validator×3**、**ord_hard×1**；另 **ord_soft** 78 条为不破契约的译段顺序软告警 (合法中文换序的常见形态)。

qualbench 缺陷榜 (1,937 已评译段，按严重度分层)：术语不一致 229、语法 197、误译 132、流畅度语域 99、幻觉内容 66、漏译片段 37、过度翻译 23、占位符破损 8。按族 × 严重度看结构：术语族 263 条 (231 轻症/32 重症) 是最大缺陷类但多为轻症；**约定族「不可译」25 条中 23 条重症**——不该译的内容被译 (参考文献/命令名)，是少量但系统性的协议违例；critical 级仅漏译 1 例。




图 12: 失败类分布。左：真实臂 $n=60$ 编译失败归因——语料源缺资产主导；右：xlatbench 271 样本翻译失败/告警类——**cs_dropped** 为头号硬失败。

5.4 门槛未过项与已知缺口

1. **死占位符 =3** (parsebench)：死占位符残留 3 例，门槛为 0——唯一未过门项，值小但需逐例归因。全量 28,904 文件中唯一解析错误为「伪装成 .tex 的 tar 包」(2211.00110 内 affinity_mat.tex)——语料源怪癖而非解析器缺陷；一致率唯一分叉文件同待逐例归因。
2. **合平 93.7% < 99%**：已知口径事项——多层语料中附属 .tex (孤儿文件，不被主文档引用) 不进合平面的占比，口径而非缺陷。
3. **alignbench 覆盖薄**：812 对中 765 对具名锚点为零——保留率指标实际只在 42 个 hyperref 对上有意义，指标口径需复核 (分母该是所有对还是仅 hyperref 对)。
4. **tectonic 短板**：EPS 路由无解 + biblatex↔biber 版本错配——EPS/bib 论文在 tectonic 下是先天缺省，路由层应前置判走 xelatex。
5. **cs_dropped 归因待定**：提示词侧约束不足 vs 网关侧截断，需在 xlatbench 加对照实验分辨。
6. **stagerun 计分卡口径**：落盘记录混存首轮欠采的过期跳过行会污染读数 (本批 989 条把联合出 PDF 冲成 7.4% 假象；按获取样本口径重算 98.75%)——工具层待加 --since/样本过滤参数。
7. **未测臂**：translators_bench、validbench (B6)、nightwatch、rundiff、trriage、stage_timing、wave、status_panel——监控/辅助工具为主，本轮未覆盖。

6 Takeaways

把六天 1,648 个 commit 与 12 臂综合读数压成十条可复用结论。每条给出数据锚点与对后续工作的含义。

1. **管线是净正的，不是成本项**。同一 80 格上，中文链 + 修复循环相对裸编译出 PDF +10 格、纯净 +21 格；compilebench 500 格中文臂纯净率反超裸编 +16.1pt。规范化 + 修复循环顺带修好了源文件自身的缺陷——「翻译引入的编译代价」被「规范化修复的源缺陷」覆盖后还有盈余。含义：对外口径可以直接说「过我们管线的论文比原样编译更容易出 PDF」。
2. **修复循环是单一最大杠杆，且收益可复现**。09-16 接线当日联合出 PDF +18.9pt (同口径复跑确认)；v2 对照 40 篇 34 个失败格救回 25 (74%)；本批真实臂 7 个管线失败格全数救回。143 条规则中装包/补件类贡献主要救回量。含义：规则沉淀速度 (31→143 条/5 天) 就是出 PDF 率的爬坡速度，机制台账 → 规则这条反馈环值得继续投入。
3. **解析硬失败面已经枯竭，残面转为告警谱**。28,904 文件解析成功 100%、一致率 99.99%，唯一解析错误是语料源怪癖 (tar 伪装成.tex)。剩下的是告警级形态 (stray_end、missing_input 各三千量级) 与泄漏长尾 (dollar 族 75 条)。含义：解析段从「修 bug」阶段进入「清长尾」阶段，优先级应让位于翻译与编译侧。
4. **泄漏归零是样本框的函数，不是终态**。dollar 族在 1,955 文件核心层清零后，8 倍体量全量复测重现 76 条命中。教训：任何「清零」结论必须绑定样本框声明；核心层绿不代表长尾绿，全量复测节奏要保持。
5. **翻译硬失败高度集中，提示词可定向修**。cs_dropped 8 例中 7 例是 \ 、\ 、~ 三个脆弱间距命令被中文熔吞吞掉——不是均匀散布的鲁棒性问题，是单一可点名机制。含义：在提示词里对这三个命令显式钉保护即可预期消灭该类大半；ph_miss 的级联丢失 (一格连丢 9 个占位

- 符) 提示要查译段级联失效而非逐点丢失。
6. **质量缺陷呈结构性分布：术语是大头轻症、约定违例是小头重症。**术语族 263 条但 231 条轻症；「不可译」约定 25 条中 23 条重症——参考文献与命令名被误译是系统性协议违例。含义：术语表资产值得继续扩（轻症面大、边际收益高），约定违例则要靠校验规则硬拦（量小但每条都是产品级事故）。
 7. **「出 PDF ≠ 成功」有实证兜底。**Mode B 注入 132 处占位符破坏，编译前被校验链 132/132 全捕获。这是整条链路最关键的不对称保证：翻译错了宁可不出 PDF，不能出一份静默错位的 PDF。含义：校验层投入（检出率、误报率、延迟三指标全绿）是产品正确性的根基，不是开销。
 8. **评测器自证过稳定性。**计分卡 schema v3 重放 loop1 得 97.89/84.99 分毫不差；报告全链路可复算（落盘记录追加式 + 样本集过滤口径）。含义：跨日对比读数可信，「指标涨了」可归因到代码而非测量噪声——这是多日迭代能收敛的前提。
 9. **基线自己会动。**裸编译地板四天涨约 19pt (71.7→90.2)，原因是离线宏包资产与 tlmgr usertree 积累——工具链成熟本身抬高了所有臂的分母。含义：任何「相对基线的增益」都要标注基线时点；「裸引擎撑死七成」这类早期结论会过期，README 与文档里的静态断言要定期复测。
 10. **未达标项与短板是显式清单，不是模糊感受。**M2 纯净率差 1.25pt (88.75 vs 90)、死占位符 3 例、合平口径 93.7%、alignbench 有效覆盖仅 42 对、tectonic 的 EPS/biber 双死穴、cs_dropped 归因待定、计分卡过期行污染——七项各有明确下一步（归因、口径修正、路由前置、对照实验、工具参数）。含义：下一里程碑的验收条件已经写死，不存在「感觉差不多了」的空间。

A 口径与数据说明

A.1 统计口径纪律

- 每个数字标注规模 n 与样本框；不同 n /口径的读数不连成同一演化线（图注注明口径切换点）。
- 计分卡读数一律按获取样本集过滤后计算——stagerun 落盘记录为追加式，跨轮重跑会残留过期行，原始行计数会把未参与样本的跳过计入分母。
- 编译终态三级：纯净 = 无告警出 PDF；带瑕 = 带可接受瑕疵出 PDF (acceptable、best_effort、dirty 三档)；联合口径出 PDF = 纯净 + 带瑕。
- 延迟为网关端到端秒；批量档入闸排队约 120s，拥塞期 p95 会被队列时间放大，读数与空闲档不可比。
- qualbench 评分由 LLM 评审 (swe-2-max) 产出，争议判例经第二评审 (swe-2-high) 仲裁；评审自身偏差未做人工标定，分数应读作相对分布而非绝对正确率。

A.2 随档清单与原始产物索引

本报告自包含：所有图表由随档 data/ 原始数据生成，引用源文档的时点快照在随档 refs/，不依赖本目录以外的路径。

目录	内容
data/	五条时间线 CSV (计分卡 / 解析 / 语料 / 规则测试 / 翻译质量); arms_history.csv 377 行评测流水 (含各轮 run 目录名、样本量、 头条读数); commits.json 1,648 commit 全录; milestones.md D0-D5 大事记
refs/	10-benchmark-suite.md (评测器规格: 七臂定义/门槛); 09-benchmark-corpus.md (语料规格: 层构造/治理); PROTOCOL.md (逐库横评协议); TIERS.md (验证分层契约 L0-L3); corpus_v3-MANIFEST.md (层语义/EVAL_ONLY); mechanisms.jsonl (机制台账快照 263 条); 00-grand-comparison.md (8 库横评, D0 定案证据); bench-metrics-corpusv3-2026-09-19.md (本批 Markdown 总表); review-2026-09-18.md + metrics-timeline.svg + assets-growth.svg (上一期复盘); overseer-selfimp-snapshot.md (车队台账 09-19 时点快照)

各臂原始评测产物 (编译工作区、译文 jsonl、PDF 中间件) 为大体量文件不入档; 溯源时按 data/arms_history.csv 的 run 目录名在评测产物存档区查找对应轮次。

A.3 过程事故记录 (评测工具链教训)

本批测试记录的评测驱动层教训, 供后续批次回避: xlatbench 的 manifest.parent 必须等于语料根 (跨目录清单会致格解析失败); --per-kind 是全局限额非分层配额; pgrep 监控须用 [x]pattern 括号形防自匹配; compilebench --gen-sample 为分段设计 (采样后即返回, 编译需无参二次调用); e2e 同 --tag 冻结样本, 重抽样须换 tag+seed; gullet --out 续跑会保留过期错误行、须换新目录; stagerun 下游阶段须显式传 --ids 防跨层欠采; 多会话共仓提交须走私有 GIT_INDEX_FILE (共享索引有 sweep/reset 竞争窗)。