

TeXlate 评测体系与指标演化全景报告

七臂 benchmark · corpus_v3 全量综合测试 · 2026-09-19

texlate bench 工作组

2026 年 9 月 19 日

摘要

本文是 TeXlate 评测体系的全景报告：上半部分为不熟悉项目的读者提供背景（管线架构、为什么 arXiv LaTeX 翻译难、benchmark 设计），下半部分是数据——全部历史 commit 考古出的指标演化时间线、2026-09-19 在 corpus_v3 全量 13,266 篇上的综合测试画像、失败归因图谱与已知缺口。全部数字可追溯：每个指标注明口径与结果目录，数据与图源文件随文档入库。

目录

1	背景知识	3
1.1	这个项目做什么	3
1.2	为什么这件事难	3
1.3	管线架构	3
1.4	术语与口径	4
2	评测体系设计	4
2.1	七臂总览	4
2.2	语料分层构造	4
2.3	门槛体系	6
3	指标演化史	6
3.1	开发节奏：六天 1,648 个 commit	6
3.2	编译健康度	6
3.3	解析侧：identity 守住，leak 四天内归零再现身	8
3.4	翻译侧：硬契约与质量评分	8
3.5	评测资产与代码规模	8
3.6	归因表：哪些改动搬动了哪些指标	8

4	2026-09-19 全量画像	8
4.1	全链漏斗：stagerun DAG	10
4.2	翻译质量：qualbench ESA 评分	10
4.3	编译臂：baseline vs zh 条件	11
4.4	翻译硬契约：xlatbench	11
4.5	e2e 全链：mock 与 real 双臂	11
5	失败归因图谱	12
5.1	编译侧失败类	12
5.2	翻译侧失败类	12
5.3	门槛 FAIL 与已知缺口	12
A	口径与数据说明	13
A.1	统计口径纪律	13
A.2	结果目录索引（2026-09-19 批）	13
A.3	过程事故记录（评测工具链教训）	14

1 背景知识

1.1 这个项目做什么

TeXlate 是「幻觉翻译」(hjfy.top) 的开源复刻：输入一篇 arXiv 论文的 LaTeX 源码 (e-print)，输出一份重编译的中文 PDF，正文逐段替换为中文译文、数学公式/图表/参考文献结构原样保留，并提供双语对照阅读。链路中的每一段都由自研组件构成：

- **获取层**：arXiv e-print 批量下载 (IA bulk / export / OAI-PMH 三通道)，钉版入库；
- **解析层**：自研半解析器——不是完整 TeX 引擎，而是「逐字符扫描 → pieces → 占位符保护 → 区间 splice」的保真切分器，外加宏展开机 (Gullet) 把用户自定义宏就地展开；
- **翻译层**：段落级 chunk 经 LLM 网关批量翻译 (swe-2 系列模型)，占位符协议保护公式与命令不被译文污染；
- **校验层**：L0/L1/L2 三层校验 (chunk 不变量、tree-sitter 结构、LLM judge)；
- **编译层**：ctex 注入 + normalize + xelatex/tectonic 双引擎编译；
- **修复层**：fixloop——131 条 YAML 规则驱动自动修复循环 (装包、改源、路由、polyfill)，把编译失败的论文迭代救回；
- **对齐层**：named-destination 锚点同步，滚动阅读时中英逐段对齐。

1.2 为什么这件事难

arXiv 源码是脏的真实世界数据。语料横跨 LaTeX2.09 (1990s) 到 2026 年：混用 plain TeX 原语与 LaTeX2.09 旧式、非 UTF-8 编码 (Big5/GBK/Latin-1)、缺文件的残缺包、tar/gz 双格式、古早宏包 (revtex4、aastex、psfig)。基线实测：裸编译 (无修复) union pdf 仅 65–72%，clean 22–40%——三分之二的论文源码直接编译不出 PDF，最大失败类是 missing_file (占裸失败 92.1%)。

宏展开是现成解析器的共同盲区。95% 的论文含自定义宏 (中位 47 个/篇，最多 446)，其中 12/39 篇手挑语料存在「宏体里藏 \begin/\end」的结构性陷阱，49% 的宏体藏 > 20 字母的可译文本。对 8 个第三方解析库 (latex-utensils、unified-latex、tree-sitter-latex、TexSoup、plasTeX、pylatexenc、LaTeX.js、ieeA) 的横评 (bench/results/00-grand-comparison.md) 表明：陷阱断言全军覆没——最好成绩 24/26 vs 自研半解析器 32/32；「能 parse」不等于「parse 对」，pylatexenc 报 90/90 成功却是静默截断零报错。**无错误信号比崩溃更危险**，这决定了主解析器必须自研、校验器必须独立。

翻译约束是结构性的。chunk 边界纪律要求公式、命令、环境标签逐字节保留，译文只能在散文区间替换；术语表一致性、学术语域 (register)、不可译段 (参考文献/版权行) 都要显式协议。编译侧中文需要 ctex 注入与 CJK 字体路由，修复侧要处理 EPS 图源、缺 sty/cls、bib 链路断点等 131 类已建档机制。

1.3 管线架构

图 1 给出全链架构与各段的 benchmark 对应关系。




图 1: TeXlate 管线架构与 benchmark 臂对应关系。主流水线自左向右；fixloop 是编译段的自动修复回环；B1-B7 为七个评测臂（虚线框），另有 fixtures 陷阱断言集做解析段单元级测试。

1.4 术语与口径

- **cell / 格**: 语料库中一篇论文的存储单元 (`{id}/{meta.json, raw.*, extracted/}`); benchmark 语境下也指一个被评对象 (paper × engine 组合)。
- **层 / layer**: corpus_v3 的抽样分层 (见 §2.2)，每层独立 manifest、独立抽样框。
- **臂 / arm**: 同一被测对象的不同处理条件——compile 的 baseline (裸编译) vs zh (产品链 normalize 后); e2e 的 mock (假翻译) vs real (真 LLM); stagerun 的 base vs zh 条件。
- **clean / pdf / FAIL**: 编译终态分级——clean 无 warning 出 PDF; pdf 带~ 可接受瑕疵出 PDF; FAIL 无 PDF。union pdf = clean + pdf。
- **identity / leak**: 解析质量两轴——identity 为 reconstruct 逐字节一致率; leak 为受保护内容 (公式/命令) 漏进可译 chunk 的占比。
- **scorecard**: gate_scorecard.py 对 stagerun records 的终态统计, M2 出口门为 union pdf ≥ 90%、clean ≥ 90%。
- **机制 / mechanism**: mechanisms.jsonl 台账登记的一类已知缺陷模式 (如 dollar 族泄漏、eps_route), benchmark 发现 → 归因 → 规则沉淀的反馈环。

2 评测体系设计

2.1 七臂总览

benchmark 套件按「每臂对准管线一段 + 一个组合层」设计, 规格冻结于 docs/10-benchmark-suite.md, 共同底材为 corpus_v3。表 1 为总览。

依赖序: corpus_v3 → B1 → B4 → {B3, B5} → B7; B2/B6 以合成输入独立。

2.2 语料分层构造

corpus_v3 是钉版批量语料: 每个 cell 记录 (channel, item, member, blob_sha256) 四元组, 渠道分 IA arxiv-bulk 月 chunk、e-print 单发、HF arxiv-latex-5T、scholarweave 脱水四种。八层构成见图 2: 核心/补强/扩展/热层为早期层, 2026-09-19 评测/开发分轨扩层后收至 13,266 篇。

治理规则: holdout 层 (3,020 篇) 登记 EVAL_ONLY_LAYERS, 所有开发期采样经 dev_layers()

表 1: 七臂 benchmark 总览 (B1–B7 + 辅助件)

#	benchmark	测哪段	底材	核心指标
B1	parsebench	解析段	corpus_v3 + corpus39	ok / identity / leak / dead / flatten
B2	fixtures	解析段 (单元级)	bench/fixtures/*.tex	陷阱断言通过率 (T01–T98)
B3	compilebench	编译段 + fixloop	corpus_v3 raw blob	clean/pdf~/FAIL、救回率、规则谱
B4	xlatbench	翻译段	corpus_v3 chunk 抽样	硬契约率 / 延迟 / token 经济
B4b	qualbench	翻译质量	e2e state 配对	LLM-judge ESA 评分 / flag 分类
B5	e2ebench	全链 (组合)	corpus_v3 子集	逐段漏斗 + 终态分布 + 引入回归
B6	validbench	校验段	合成破坏案例	检出率 / FP / 延迟
B7	alignbench	阅读体验	en/zh 编译产物对	named-dest 保留率 / 链权

辅助件: stagerun (五阶段批量 DAG)、gullet_bench (展开机实测)、
gate_scorecard (M2 出口门)、translators_bench (mock 臂工厂)、nightwatch




图 2: corpus_v3 八层构成 (13,266 篇 / 46GB)。holdout 层为 EVAL_ONLY 治理——dev_layers() 实测排除，仅评测可读；dev_* 三层与 expand 为开发期增量；core 为月度簇分层随机 (30 簇，old 200/new 800)。

过滤；语料扩展只加层不删层；cell 数据 gitignored，入库物为 manifest + 选择报告 + 机制台账 mechanisms.jsonl (benchmark → 归因 → 规则沉淀的反馈环载体)。

2.3 门槛体系

各臂门槛 (docs/09 §8)：parsebench——parse ok 100%、identity $\geq 99.5\%$ 、leak $\leq 0.15\%$ 、dead-orphan = 0、flatten $\geq 99\%$ ；M2 出口门 (stagerun scorecard) ——union pdf $\geq 90\%$ 、clean $\geq 90\%$ 。统计口径：核心层加权池化率 + 宏平均双报，Wilson + 月簇稳健 bootstrap CI。

3 指标演化史

本节数据来自三路考古：全部 1,648 条历史 commit 逐条扫描 (里程碑识别)、bench/results/377 个日期目录的读数回填、docs/research/overseer-selfimp.md 台账与 review-2026-09-18 复盘 (口径锚点)。原始数据随文档入库于 data/ 子目录 (scorecard/parse/corpus/rules-tests/qualxlat 五条时间线 CSV + 377 行评测活动流水 + 1,648 行 commit 全录 + milestones.md)；口径不一的读数分线绘制并注明样本框。

3.1 开发节奏：六天 1,648 个 commit




图 3: commit 日吞吐 (累计 1,648)。09-17 峰值 624 对应「波次战」(vendor shim/illegal_unit/段修多车道并行收割)；全程为多代理车队协作模式 (overseer 台账记 roster 峰值 ~23 车道)，commit 由 leader 会话统一落盘。

项目节奏呈「日主题」结构 (图 3、表 2)：D0 立项与八库横评定案、D1 产品骨架 (七臂同日落地)、D2 v2 切换 + fixloop 接线 (最大单日指标跃升)、D3 波次战收割残面、D4 selfimp 常驻环、D5 语料收官 + 全量综合测试。

3.2 编译健康度

三条叙事线 (图 4)：fixloop 是单一最大杠杆——09-16 接产品链当日 union pdf +18.9pt (70.6→89.5, 同 n180 复跑)；波次战把残面打成个位数——vendor 波翻 492 格 fail 面、illegal_unit 108/108 闭环、scorecard 一波 89.17→97.89；real 与 mock 打平——realn200 union pdf 98.5% 证明评测面非虚高，今日 e2e-v3b 终态 96.7% (7 个 pipe-fail 全被 fixloop 救回、2 格 oversize 跳过)。未达标字面只剩 M2 clean $\geq 90\%$ (今 88.75%, -1.25pt)。

表 2: 六日大事记 (commit 考古, 精选)

日	主题	标志事件
D0 09-14	立项定案	仓库初始化; 8 库横评 (39 篇 + 30 fixtures) —— miniscanner 陷阱 32/32、identity 259/259 定案自研路线; 技术栈 ADR 冻结
D1 09-15	产品骨架	miniscanner 重写为 <code>texlate/latex</code> 九文件; Mouth+Gullet 展开机; <code>compile/xlat/server/</code> 阅读器全套; 七臂同日落地 ; <code>fixloop</code> 25 规则移植; 语料 $\rightarrow 1,339$
D2 09-16	切换 + 接线	v2 cutover (<code>splice</code> 残留 1524 $\rightarrow$ 0); fixloop 接线 (pdf +18.9pt); <code>expand+hot</code> 层语料 $\rightarrow 5,410$; <code>loop1</code> $n=5124$ scorecard 97.89%; <code>qualbench</code> 诞生
D3 09-17	波次战	<code>vendor</code> 23 件翻 492 格; <code>illegal_unit</code> 108 闭环; ReDoS 修复 <code>pytest</code> 48min $\rightarrow$ 3:46; <code>xlat</code> P0 封死错配通道; realn200 98.5% 真臂验收
D4 09-18	selfimp 环	常驻改进环 23 车道发车; <code>loop2</code> 97.26%/86.42%; dollar 族 leak 清零 ; <code>qualbase</code> 92.9 建档; <code>corpus_daily</code> 日更渠启动
D5 09-19	收官 + 全量	corpus_v3 八层 13,266 篇 (dev/eval 分治); 完整性审计全绿; 12 臂综合测试同日落地 (本报告主体); <code>loop3</code> 在飞




图 4: 编译健康度时间线。scorecard 线为 stagerun records 在代码演进下的重评 (`loop1` $n=5124 \rightarrow$ `loop2` $n=5219 \rightarrow$ `v3all` 样本 $n=80$); `real` 臂为真 LLM 翻译全链 (`realn200` $\rightarrow$ `e2e-v3b` $n=60$ 终态); 方块为裸编译基线——注意基线自身四天涨 $\sim 19\text{pt}$ (71.7 $\rightarrow$ 90.2): `vendored` 宏包资产 + `tlmgr` `usertree` 积累使工具链整体成熟,「裸引擎撑死七成」的 09-15 结论已不适用今日地板。

3.3 解析侧：identity 守住，leak 四天内归零再现身




图 5：解析侧演化。左：leak 命中数——dollar 族 58/57 条残留于 09-18 c2-dollar 车道清零（核心层口径），09-19 全量 28,904 文件上重现 76 条（1,845,338 chunk 中 0.004%，新语料表面新案例，非回归）。右：strict identity 全测量期 $\geq 99.99\%$ （纵轴截断）。

解析侧四天稳态（图 5）：v2 Gullet+Segmenter cutover 当日 splice 残留占位符 1524 $\rightarrow$ 0；leak 残留清一色 dollar 族，09-18 单类收口归零——但归零是在 1,955 文件核心层上，今日 8 倍体量全量复测重现 76 条命中，说明该族机制在长尾语料上未穷举，属于「已识别族的覆盖率问题」而非新机制。

3.4 翻译侧：硬契约与质量评分




图 6：翻译侧演化。左：swe-2-medium 硬契约率——09-15 smoke 期网关不稳（http_err 17）压到 64.6%，契约批 98.8%，今日全层抽样 93.7%（新校验口径 v_err 27 条计入后更严）；右：ESA judge 均分 92.9 $\rightarrow$ 94.0（swe-2-max 评审，contested 8.1% $\rightarrow$ 5.5% 下降）。

3.5 评测资产与代码规模

3.6 归因表：哪些改动搬动了哪些指标

4 2026-09-19 全量画像

本节为 corpus_v3 扩充收官（13,266 篇）后的首轮全量综合测试，12 个评测臂同日落地。总表见表 4，逐节展开关键分布。




图 7: 资产增长 (git 历史抽样, 同日口径一致): pytest 798→6,450、fixloop 规则 31→143 (16 分片)、src 72→425 文件、语料 corpus39/v2 → v3 八层 13,266 (另有 corpus_daily 日更渠 ~1,200 篇/日在库外增长)。

表 3: 改动 → 指标位移归因 (commit 级, 摘自台账与各波报告)

日期	改动 (commit)	指标位移
09-14	8 库横评 + miniscanner spike	主解析器路线定案 (陷阱 32/32, identity 259/259)
09-15	corpus_v3 core+booster + 双引擎基线	基线口径建立 (union pdf 71.7%/clean 39.4%, n180)
09-15	fixloop yaml 引擎落地 (179f7e5b)	25 条规则移植, 修复臂诞生
09-16	fixloop 接产品链 (3d5de8f7)	union pdf 70.6→89.5% (+18.9pt, 同口径复跑)
09-16	v2 Gullet+Segmenter 默认切换 (f4616838)	splice 残留占位符 1524→0 (cutover 硬门)
09-16	argspec.json 入包 (401e9bbf)	1820 条宏参规格零装载 GAP 闭合
09-16	perf-tail 五修	latex parse 长尾 -48% (51476→26723ms), identity 零回退
09-16	stagerun loop1 全 DAG (n=5124)	scorecard 97.89%/84.99%; fixloop rescue 84.0%
09-17	vendored_fetch + vendor 23 件 (a90978ab)	绝版宏包缺件面 492 格 fail→73.2% clean, clean +101 格
09-17	illegal_unit 段修波 (d2c377bd)	108/108 闭环零回归, clean 84.76→85.03%
09-17	ReDoS 原子组修复 (746237fd)	held6 卡死 30min+→0.1s; pytest 全量 48min→3:46
09-17	xlat 非锚定 [n] parse 撤除 (164a9e0f, P0)	译文静默错配通道封死, 同批核销 4 P1
09-17	realn200 真臂验收 (f2847c33)	union pdf 197/200=98.5%, 与 mock 打平
09-18	c2-dollar 车道收口	leak 57→0/136,049 chunks (核心层口径单类清零)
09-18	gate_scorecard schema v3	loop1 复跑 97.89/84.99 分毫不差——评测器自证稳定
09-18	qualbase esa2 (n=1200)	质量基线建档 mean 92.9 [92.4,93.3], contested 8.1%
09-18	loop2 冻结快照 (n=5219)	scorecard 97.26%/86.42% (clean +1.43pt)
09-19	corpus 8 层扩层 (13c603cf)	语料 5232→13,266, EVAL_ONLY 治理落地
09-19	全量综合测试 (本报告)	12 臂同日落地; 基线地板升至 90.2%; stagerun 98.75%/88.75%

表 4: 2026-09-19 综合测试逐臂指标总表

臂	规模	核心指标	门槛对比
完整性审计	13,266 cells	sha256 13,266/13,266, 0 dup, 0 missing; 13 stub 为 B07 有意构造	EVAL_ONLY 生效
parsebench	13,253 篇 / 28,904 .tex	parse ok 100.0% ; identity 99.99% ; leak 0.004% (76/1,845,338) ; expand footprint strict 28105/norm 259/div 539; flatten 93.7%	identity/leak PASS; dead ph=3 FAIL; flatten FAIL
compilebench base	500 格 ×2	xelatex 56.3% clean/80.3% pdf; tectonic 38.6%/62.4%; 联合 pdf 90.4%	—
compilebench zh	500 格	xelatex 72.4%/85.4% (+16pt); tectonic 45.7%/59.8%	—
fixloop (v2 40)	80 格	xelatex 34 FAIL→ 25 救回 74% ; tectonic 1/16 (eps_route 主导)	—
alignbench	812 对	门全过; 765/812 对 named-dests= 0, 真实覆盖 42 对 (retention p50 1.0)	覆盖不足
e2e_mock	corpus39	pipe-xel 33/39 clean vs base-xel 19/39; 引入回归 3	—
e2e_real	n=24+60	58/58 翻译; chunk ok 6053/7580; splice 残留 0 ; pipe-xel clean 43/fail 7; fixloop 再救 13; 0 引入回归	—
xlatbench	271 样本	hard_ok 94% ; http_err 0; 延迟 p50 4.2s/p95 29.7s	—
qualbench	324 篇/1937 chunk	judge 均分 94.0 , median 95; ≥90 占 90.6%; contested 5.5%; critical 1	—
gullet	200 文档	199/200 展开成功; median 39.6ms/19 steps	—
stagerun DAG	80 篇跨层	union pdf 79/80=98.75% ; clean 71/80=88.75%	M2 pdf 门 PASS

4.1 全链漏斗：stagerun DAG

五阶段批量驱动对 80 篇跨层样本的实测漏斗（图 8）：ingest 80 → parse 79 ok (1 reject) → xlat zh 臂 76 ok + 3 partial → compile 50 clean + 19 partial + 10 fail → fixloop 对 21 个非 clean 格全数救回 (13 升 clean + 8 partial)。联合口径 union pdf 98.75%、clean 88.75%，过 M2 union-pdf ≥ 90% 门；clean 距 90% 门差 1.25pt。




图 8: stagerun 五阶段漏斗（80 篇跨层样本，zh 臂 / mock 上游）。compile 产出 50 clean+19 partial+10 fail；fixloop 将 21 个非 clean 格全部推到 pdf 层（13 clean+8 partial），union pdf 79/80。

4.2 翻译质量：qualbench ESA 评分

swe-2-medium 译文对 324 篇论文 1,937 个 chunk 的 LLM-judge 评分（judge=swe-2-max，二裁 swe-2-high，contested 5.5% 触发二裁）：mean 94.0 / median 95，≥90 分占 90.6%，critical 级缺陷仅 1 例（non-translation）。分数段与文类分布见图 9：section_title 最高（96.9），caption 93.2，para 92.2——长散文段仍是质量洼地。




图 9: qualbench 评分分布 (左: 分数段; 右: per-kind 均分)。1,756/1,937 chunk ≥90; para 类是主要拉低项 (flag 榜: term_inconsistency 229、grammar 197、mistranslation 132、hallucinated_content 66)。

4.3 编译臂: baseline vs zh 条件

500 格抽样双引擎对照 (图 10): zh 条件 (产品链 normalize + ctex 注入后编译) 反而比裸编译高 16pt clean——normalize 顺带修复了源文件的编码/格式缺陷。tectonic 在 zh 臂 clean 升而 pdf 略降, EPS 图源是其死穴 (见 §5)。




图 10: compilebench 500 格: baseline vs zh 条件。zh 臂 xelatex clean +16.1pt——normalize 修复了源级缺陷; union pdf 90.4% (双引擎取优)。

4.4 翻译硬契约: xlatbench

271 个抽样上下文对 swe-2-medium 的硬契约测试: hard_ok 94%, http_err 0。延迟 p50 4.2s / p95 29.7s——bg 批量档 ~120s in-gate 排队在长尾可见。失败类: cs_dropped×8、ph_miss×5、validator×3、ord_hard×1; ord_soft 78 条软序告警。

4.5 e2e 全链: mock 与 real 双臂

e2e_mock (corpus39): pipe-xel 33/39 clean vs base-xel 19/39——管线净正, 翻译 +splice 步骤无损反而增益 (normalize 修复); 3 格引入回归。e2e_real n=60: 58/58 翻译完成, chunk ok 6053/7580 (partial 43/fault 8), splice 残留占位符 0 (PASS), pipe-xel clean 43/fail 7/partial 6, fixloop 再救 13 格, 0 管线引入回归。编译失败类: missing_file×7、missing_graphic×3、

killed_by_signal×3、driver_fatal×3——以语料源缺资产为主。

5 失败归因图谱

5.1 编译侧失败类

e2e_real n=60 的编译失败归因 (图 11 左): missing_file×7 与 missing_graphic×3 合计过半——语料源自身缺资产 (arXiv e-print 打包不全), 非管线引入; killed_by_signal×3 为超时/资源类; driver_fatal×3 为引擎级崩溃。

fixloop 救回矩阵 (corpus_v2 40 篇对照): xelatex 34 个 FAIL 格救回 25 (74%), 主力规则为 install_file (14 触发, 8 格出 pdf)、install_tfm (12 触发, 7 格)、static_precheck (40 格全触发); 装包榜首位 subfigure.sty×10、revtex4.cls×9。tectonic 臂仅救 1/16——**eps_route reject 是结构性死穴** (11 格全拒): EPS 图源在 tectonic/xdvipdfmx 通路无解, 唯一出路是路由 xelatex。另有 latex209_reject 闸拦下 LaTeX2.09 古文 8 格 (该类论文需 209→2e 重写通道, 非装包可救)。

5.2 翻译侧失败类

xlatbench 失败类分布 (图 11 右, 17 个 hard_fail 全归因): **cs_dropped×8 居首**——控制序列在译文中丢失 (占位符协议被破坏的最常见形态); ph_miss×5 (占位符未还原)、validator×3、ord_hard×1; 另 ord_soft 78 条为不破契约的 chunk 顺序软告警。qualbench flag 榜 (1,937 judged chunk): term_inconsistency 229、grammar 197、mistranslation 132、fluency_register 99、hallucinated_content 66、untranslated_spans 37、over_translation 23、placeholder_broken 8。




图 11: 失败类分布。左: e2e_real n=60 编译失败归因——语料源缺资产主导; 右: xlatbench 271 样本翻译失败/告警类——cs_dropped 为头号硬失败。

5.3 门槛 FAIL 与已知缺口

1. **dead protect ph=3** (parsebench): 死占位符残留 3 例, 门为 0——唯一 gate FAIL 项, 值小但需逐例归因。
2. **flatten 93.7% < 99%**: 已知 errata, orphan tex 清单在 papers.json (多层语料中 .tex 不进主文档 flatten 面的占比)。

3. **alignbench 覆盖薄**: 812 对中 765 对 named-dests 为零——保留率指标实际只在 42 个 hyperref 对上有意义, 指标口径需复核 (分母该是所有对还是仅 hyperref 对)。
4. **tectonic 短板**: eps_route 无解 + biblatex↔biber 版本错配——EPS/bib 论文在 tectonic 下是先天缺省, 路由层应前置判走 xelatex。
5. **cs_dropped 归因待定**: prompt 侧约束不足 vs 网关侧截断, 需在 xlatbench 加对照实验分辨。
6. **stagerun scorecard 口径**: records 混存首轮欠采的 stale skip 行会污染读数 (本批 989 条把 union pdf 冲成 7.4% 假象; 按 ingest 样本口径重算 98.75%) ——工具层待加 `--since`/样本过滤参数。
7. **未测臂**: translators_bench、validbench (B6)、nightwatch、rundiff、trriage、stage_timing、wave、status_panel——监控/辅助工具为主, 本轮未覆盖。

A 口径与数据说明

A.1 统计口径纪律

- 每个数字标注规模 n 与样本框; 不同 n /口径的读数不连成同一演化线 (图注注明口径切换点)。
- scorecard 读数一律按 ingest 样本集过滤后计算——stagerun records 为 append-only, 跨轮重跑会残留 stale 行, 原始行计数会把未参与样本的 skip 计入分母。
- clean/pdf 为编译终态分级: clean = 无 warning 出 PDF; pdf~ = 带可接受瑕疵出 PDF (acceptable/best_effort/dirty 三档); union pdf = clean + pdf~。
- 延迟为网关端到端秒; bg 批量档 in-gate 排队 ~120s, 拥塞期 p95 会被队列时间放大, 读数与空闲档不可比。
- qualbench 评分由 LLM judge (swe-2-max) 产出, contested 判例经第二 judge (swe-2-high) 仲裁; judge 自身偏差未做人工标定, 分数应读作相对分布而非绝对正确率。

A.2 结果目录索引 (2026-09-19 批)

臂	bench/results/ 目录
parsebench 全量	parsebench-v3-all-2026-09-19/
compilebench baseline	compilebench-v3-2026-09-19/
compilebench zh	compilebench-v3-zh-2026-09-19/
xlatbench 全层	xlatbench-v3all-2026-09-19/
qualbench	qualbench-e2ereal-2026-09-19/report.md
e2e_real	e2e-real-v3-2026-09-19-*/ (n=24)、e2e-real-v3b-* (n=60)
e2e_mock	e2e-mock-2026-09-19-2026-09-19/
alignbench	alignbench-e2ereal-2026-09-19/
gullet	gullet-v3-2026-09-19/
stagerun DAG	stagerun-v3all-2026-09-19/records/
fixloop	fixloop-corpusv2-2026-09-15/

配套文档:本批 Markdown 版总表 docs/research/2026-09-19-bench-metrics-corpusv3.md; 上一期指标复盘 docs/research/review-2026-09-18/README.md (含 metrics-timeline.svg); 评测器规格 docs/10-benchmark-suite.md; 语料规格 docs/09-benchmark-corpus.md; 机制台账 bench/corpus_v3/mechanisms.jsonl。

A.3 过程事故记录 (评测工具链教训)

本批测试记录的 harness 层教训, 供后续批次回避: xlatbench 的 manifest.parent 必须等于语料根 (跨目录 manifest 会 cell 解析失败); --per-kind 是全局限额非分层配额; pgrep 监控须用 [x]pattern 括号形防自匹配; compilebench --gen-sample 为分段设计 (采样后即返回, 编译需无参二次调用); e2e 同 --tag 冻结样本, 重抽样须换 tag+seed; gullet --out 续跑保留 stale err 行须换新目录; stagerun 下游阶段须显式传 --ids 防跨层欠采; 多会话共仓 commit 须走私有 GIT_INDEX_FILE (共享 index 有 sweep/reset 竞争窗)。