

TeXlate 评测体系与指标演化全景报告

七臂 benchmark · corpus_v3 全量综合测试 · 2026-09-19

texlate bench 工作组

2026 年 9 月 19 日

摘要

本文是 TeXlate 评测体系的全景报告：上半部分为不熟悉项目的读者提供背景（管线架构、为什么 arXiv LaTeX 翻译难、benchmark 设计与评测现场布局），下半部分是数据——全部历史 commit 考古出的指标演化时间线、2026-09-19 在 corpus_v3 全量 13,266 篇上的综合测试画像、失败归因图谱与已知缺口。全部数字可追溯：每个指标注明口径与样本框；文档自包含——全部原始数据在随档 `data/`，引用源文档快照在随档 `refs/`，不依赖本目录以外的路径。

目录

1	背景知识	3
1.1	这个项目做什么	3
1.2	为什么这件事难	3
1.3	管线架构	3
1.4	术语与口径	3
2	评测体系设计	5
2.1	七臂总览	5
2.2	评测现场：bench/ 的构成	5
2.3	语料分层构造	7
2.4	门槛体系	7
3	指标演化史	7
3.1	开发节奏：六天 1,648 个 commit	8
3.2	编译健康度	8
3.3	解析侧：identity 守住，leak 四天内归零再现身	9
3.4	翻译侧：硬契约与质量评分	10
3.5	评测资产与代码规模	10
3.6	归因表：哪些改动搬动了哪些指标	10

4	2026-09-19 全量画像	10
4.1	全链漏斗：stagerun DAG	10
4.2	翻译质量：qualbench ESA 评分	12
4.3	编译臂：baseline vs zh 条件	13
4.4	翻译硬契约：xlatbench	13
4.5	e2e 全链：mock 与 real 双臂	14
5	失败归因图谱	14
5.1	解析侧失败面	14
5.2	编译侧失败类	14
5.3	翻译侧失败类	14
5.4	门槛 FAIL 与已知缺口	15
A	口径与数据说明	16
A.1	统计口径纪律	16
A.2	随档清单与原始产物索引	16
A.3	过程事故记录（评测工具链教训）	17

1 背景知识

1.1 这个项目做什么

TeXlate 是「幻觉翻译」(hjfy.top) 的开源复刻：输入一篇 arXiv 论文的 LaTeX 源码 (e-print)，输出一份重编译的中文 PDF，正文逐段替换为中文译文、数学公式/图表/参考文献结构原样保留，并提供双语对照阅读。链路上的每一段都由自研组件构成：

- **获取层**：arXiv e-print 批量下载 (IA bulk / export / OAI-PMH 三通道)，钉版入库；
- **解析层**：自研半解析器——不是完整 TeX 引擎，而是「逐字符扫描 → pieces → 占位符保护 → 区间 splice」的保真切分器，外加宏展开机 (Gullet) 把用户自定义宏就地展开；
- **翻译层**：段落级 chunk 经 LLM 网关批量翻译 (swe-2 系列模型)，占位符协议保护公式与命令不被译文污染；
- **校验层**：L0/L1/L2 三层校验 (chunk 不变量、tree-sitter 结构、LLM judge)；
- **编译层**：ctex 注入 + normalize + xelatex/tectonic 双引擎编译；
- **修复层**：fixloop——143 条 YAML 规则驱动自动修复循环 (装包、改源、路由、polyfill)，把编译失败的论文迭代救回；
- **对齐层**：named-destination 锚点同步，滚动阅读时中英逐段对齐。

1.2 为什么这件事难

arXiv 源码是脏的真实世界数据。语料横跨 LaTeX2.09 (1990s) 到 2026 年：混用 plain T_EX 原语与 LaTeX2.09 旧式、非 UTF-8 编码 (Big5/GBK/Latin-1)、缺文件的残缺包、tar/gz 双格式、古早宏包 (revtex4、aastex、psfig)。基线实测：裸编译 (无修复) union pdf 仅 65–72%，clean 22–40%——三分之二的论文源码直接编译不出 PDF，最大失败类是 missing_file (占裸失败 92.1%)。

宏展开是现成解析器的共同盲区。95% 的论文含自定义宏 (中位 47 个/篇，最多 446)，其中 12/39 篇手挑语料存在「宏体里藏 \begin/\end」的结构性陷阱，49% 的宏体藏 > 20 字母的可译文本。对 8 个第三方解析库 (latex-utensils、unified-latex、tree-sitter-latex、TexSoup、plasTeX、pylatexenc、LaTeX.js、ieeA) 的横评 (原始报告随档 refs/) 表明：陷阱断言全军覆没——最好成绩 24/26 vs 自研半解析器 32/32；「能 parse」不等于「parse 对」，pylatexenc 报 90/90 成功却是静默截断零报错。**无错误信号比崩溃更危险**，这决定了主解析器必须自研、校验器必须独立。

翻译约束是结构性的。chunk 边界纪律要求公式、命令、环境标签逐字节保留，译文只能在散文区间替换；术语表一致性、学术语域 (register)、不可译段 (参考文献/版权行) 都要显式协议。编译侧中文需要 ctex 注入与 CJK 字体路由，修复侧要处理 EPS 图源、缺 sty/cls、bib 链路断点等 ~260 类已建档机制。

1.3 管线架构

图 1 给出全链架构与各段的 benchmark 对应关系。

1.4 术语与口径

后文所有指标沿用本节口径；遇到生词先查此表。




图 1: TeXlate 管线架构与 benchmark 臂对应关系。主流水线自左向右; fixloop 是编译段的自动修复回环; B1-B7 为七个评测臂 (虚线框), 另有 fixtures 陷阱断言集做解析段单元级测试。

- **cell / 格**: 语料库中一篇论文的存储单元 (`{id}/{meta.json, raw.*, extracted/}`); benchmark 语境下也指一个被评对象 (paper × engine 组合)。
- **层 / layer**: corpus_v3 的抽样分层 (见 §2.3), 每层独立 manifest、独立抽样框。**EVAL_ONLY** 层为评测专用, 开发期采样一律经 `dev_layers()` 排除。
- **臂 / arm**: 同一被测对象的不同处理条件——compile 的 base (裸编译) vs zh (产品链 normalize+ctex 后); e2e/xlat 的 **mock** (确定性假翻译, 零成本可复现) vs **real** (真 LLM 网关); stagerun 的 base 为归因对照臂、zh 为产品链臂。编译条件记号: pipe-xel = 产品链后 xelatex 编译, pipe-fix = fixloop 修复后再编。
- **chunk / piece**: piece 为解析器输出的片段 (散文/公式/命令等类型); chunk 为翻译最小单位 (段落级, 由 piece 聚合而来), 本批语料均长 211 字符。
- **flatten**: 多文件论文 (`\input/\include` 树) 合并为单一 .tex 的预处理; orphan tex 为不被主文档引用的附属文件 (随附 preamble/poster 件), 不计入 flatten 覆盖。
- **splice / splice 残留**: 重建步骤——把译文 chunk 按占位符区间替换回源文骨架; splice 残留 = 重建后仍残留的占位符数, 正常应为 0。
- **clean / partial (pdf~) / FAIL**: 编译终态分级——clean 无 warning 出 PDF; partial/pdf~ 带可接受瑕疵出 PDF (records 记作 partial, 报告行文写 pdf~); FAIL 无 PDF。**union pdf = clean + partial**。
- **union 口径**: scorecard 的 union pdf 是「阶段并集」——每格取 compile 与 fixloop 两段较优终态; 与之相对的 end-state 口径只看最末段状态。base 臂是归因基线, 不入 union。
- **identity / leak**: 解析质量两轴——identity 为 reconstruct 逐字节一致率; leak 为受保护内容 (公式/命令) 漏进可译 chunk 的占比。
- **dead / orphan**: 解析侧两类零容缺——dead protect ph = 占位符未被任何 chunk 消费 (死占位符); orphan chunks = 译文 chunk 找不到回填位置。
- **stagerun / scorecard**: stagerun 为五段批量驱动 (ingest→parse→xlat→compile→fixloop, records append-only 逐格落盘); scorecard 为 `gate_scorecard` 对 records 的终态统计, M2 出口门 union pdf ≥ 90%、clean ≥ 90%。
- **hard_ok / 契约族**: xlatbench 的硬契约判定——占位符全还原 (ph_missing/ph_invented)、控制序列保留 (cs_dropped)、结构校验通过 (validator_ok)。顺序类分 ord_hard (破契约) 与 ord_soft (合法中文换序软告警, 不计败)。

- **ESA / contested**: qualbench 的 LLM-judge 协议——judge 按 ESA 错误分类打 0–100 分；judge 与二裁分歧的判例记 contested，由第二 judge 仲裁。
- **named-dest**: PDF 具名锚点 (hyperref \label 位点)；alignbench 测中英双版锚点保留率以实现逐段对齐。
- **fixloop / 机制 / 车道**: fixloop 为 YAML 规则驱动的编译修复循环；mechanism 为 mechanisms.jsonl 台账 (快照随档 refs/) 登记的已知缺陷模式 (dollar 族泄漏、eps_route 等)，benchmark 发现 → 归因 → 规则沉淀的反馈环；车道/波次为多代理并行修一批同族缺陷的工作单元；**selfimp 环** (self-improvement loop) 为 09-18 起常驻的多代理改进环 (车队台账快照随档 refs/)。
- **v2 cutover**: 09-16 解析主路径从 v1 逐字符扫描器切到 v2 Gullet 展开机 + Segmenter 的事件，cutover 硬门为 splice 残留占位符清零。
- **bg 档**: 网关批量档——低优先级队列，in-gate 排队 ~120s，bench 批跑默认档位，延迟读数含排队时间。

2 评测体系设计

2.1 七臂总览

benchmark 套件按「每臂对准管线一段 + 一个组合层」设计，评测器规格冻结件随档于 refs/ (10-benchmark-suite.md)，共同底材为 corpus_v3。表 1 为总览。

表 1: 七臂 benchmark 总览 (B1–B7 + 辅助件)

#	benchmark	测哪段	底材	核心指标
B1	parsebench	解析段	corpus_v3 + corpus39	ok / identity / leak / dead / flatten
B2	fixtures	解析段 (单元级)	手构陷阱 .tex 集 (10 件)	陷阱断言通过率 (T01–T98)
B3	compilebench	编译段 + fixloop	corpus_v3 raw blob	clean/pdf~/FAIL、救回率、规则谱
B4	xlatbench	翻译段	corpus_v3 chunk 抽样	硬契约率 / 延迟 / token 经济
B4b	qualbench	翻译质量	e2e state 配对	LLM-judge ESA 评分 / flag 分类
B5	e2ebench	全链 (组合)	corpus_v3 子集	逐段漏斗 + 终态分布 + 引入回归
B6	validbench	校验段	合成破坏案例	检出率 / FP / 延迟
B7	alignbench	阅读体验	en/zh 编译产物对	named-dest 保留率 / 链权

辅助件: stagerun (五阶段批量 DAG)、gullet_bench (展开机实测)、gate_scorecard (M2 出口门)、translators_bench (mock 臂工厂)、nightwatch

依赖序: corpus_v3 → B1 → B4 → {B3, B5} → B7; B2/B6 以合成输入独立。

2.2 评测现场: bench/ 的构成

所有评测资产集中在仓库 bench/ 树，入口文档为 PROTOCOL.md (逐库横评协议) 与 TIERS.md (验证分层契约，均随档 refs/)。后者定义「一个问题该在哪一级被抓住」: L0 单测/fixture 断言 (秒级，CI 硬门) → L1 corpus 机制覆盖 (分钟级) → L2 stagerun 子集回归 (分钟–小时，机制台账定向重放) → L3 全层全臂过夜集成 (里程碑门)；规则是「能低不高」——低层能钉的不许只在批量上撞见，批量发现的真坑要沉淀回 L0。本报告 B1–B7 属 L1–L3 层读数。布局与职能：

表 2: bench/ 现场布局（不熟悉仓库的读者对照此表读结果目录名）

路径	内容
bench/py/	37 个评测脚本，分四簇—— 批量驱动 : stagerun.py + stage_{ingest,parse,xlat,compile,fixloop}（五段 DAG, records 逐格 append-only 落盘）； 七臂 harness : parsebench、compilebench_v3、xlatbench、qualbench、e2e_mock_bench、e2e_real_bench、fixloop_bench、alignbench、validbench、gullet_bench、fixture_assert； 门禁监控 : gate_scorecard（M2 出口门）、status_panel、nightwatch、rundiff、trriage、wave、stage_timing； 支撑件 : benchlib 公共库、translators_bench（mock 翻译厂）、corpus/ 语料构建管线、iclr_* 对照语料渠、report/ 一次性审计、scratch/ 探针
bench/ts/	JS 侧三库横评 harness（latex-utensils/unified-latex/tree-sitter-latex），D0 选型证据产地
bench/corpus*	语料族: corpus 39 篇手挑陷阱、corpus_v2 139 篇分层、corpus_v3 13,266 篇八层钉版 (§2.3)、corpus_daily RSS 日更渠（~1,200 篇/日）、corpus_iclr* ICLR 对照渠
bench/fixtures/	10 件手构陷阱 .tex (@Tnn/@Wnn/@Xn 断言标记: T 为结构陷阱、W 为野外发现机制、X 为翻译层；逐字节即语义，不做任何格式化)
bench/results/	评测产物区: 每次运行一个日期目录（377+ 轮累积），含 records/summary/jsonl/PDF 中间件；大体量不入档，本报告读数全部由其抽取进 data/
bench/work_*/	编译/fixloop 逐格工作区（解压源树、aux、PDF；重产物 gitignored）

2.3 语料分层构造

corpus_v3 是钉版批量语料：每个 cell 记录 (channel, item, member, blob_sha256) 四元组，渠道分 IA arxiv-bulk 月 chunk、e-print 单发、HF arxiv-latex-5T、scholarweave 脱水四种。八层构成见图 2：核心/补强/扩展/热层为早期层，2026-09-19 评测/开发分轨扩层后收至 13,266 篇。




图 2: corpus_v3 八层构成 (13,266 篇 / 46GB)。holdout 层为 EVAL_ONLY 治理——dev_layers() 实测排除，仅评测可读；dev_* 三层与 expand 为开发期增量；core 为月度簇分层随机 (30 簇，old 200/new 800)。

治理规则：holdout 层 (3,020 篇) 登记 EVAL_ONLY_LAYERS，所有开发期采样经 dev_layers() 过滤；语料扩展只加层不删层；cell 数据 gitignored，入库物为 manifest + 选择报告 + 机制台账 mechanisms.jsonl (两者快照均随档 refs/；台账是 benchmark → 归因 → 规则沉淀的反馈环载体)。

2.4 门槛体系

各臂门槛 (语料规格 §8，随档 refs/)：parsebench——parse ok 100%、identity $\geq 99.5\%$ 、leak $\leq 0.15\%$ 、dead-orphan = 0、flatten $\geq 99\%$ ；M2 出口门 (stagerun scorecard) ——union pdf $\geq 90\%$ 、clean $\geq 90\%$ 。统计口径：核心层加权池化率 + 宏平均双报，Wilson + 月簇稳健 bootstrap CI。

3 指标演化史

本节数据来自三路考古：全部 1,648 条历史 commit 逐条扫描 (里程碑识别)、评测结果流水 377 个日期目录的读数回填、车队台账与上一期复盘 (口径锚点)。本文档自包含：原始数据入库于随档 data/ 子目录 (scorecard/parse/corpus/rules-tests/qual-xlat 五条时间线 CSV + 377 行评测活动流水含各轮 run 目录名 + 1,648 行 commit 全录 + milestones.md)，引用源文档时点快照在随档 refs/ (台账、复盘、评测器与语料规格、8 库横评报告、机制台账)；口径不一的读数分线绘制并注明样本框。




图 3: commit 日吞吐 (累计 1,648)。09-17 峰值 624 对应「波次战」(vendor shim/illegal_unit/段修多车道并行收割); 全程为多代理车队协作模式 (overseer 台账记 roster 峰值 ~23 车道), commit 由 leader 会话统一落盘。

3.1 开发节奏：六天 1,648 个 commit

项目节奏呈「日主题」结构 (图 3、表 3): D0 立项与八库横评定案、D1 产品骨架 (七臂同日落地)、D2 v2 切换 + fixloop 接线 (最大单日指标跃升)、D3 波次战收割残面、D4 selfimp 常驻环、D5 语料收官 + 全量综合测试。

表 3: 六日大事记 (commit 考古, 精选)

日	主题	标志事件
D0 09-14	立项定案	仓库初始化; 8 库横评 (39 篇 + 30 fixtures) —— miniscanner 陷阱 32/32、identity 259/259 定案自研路线; 技术栈 ADR 冻结
D1 09-15	产品骨架	miniscanner 重写为 <code>texlate/latex</code> 九文件; Mouth+Gullet 展开机; <code>compile/xlat/server/</code> 阅读器全套; 七臂同日落地 ; <code>fixloop</code> 25 规则移植; 语料 → 1,339
D2 09-16	切换 + 接线	v2 cutover (splice 残留 1524→0); fixloop 接线 (pdf +18.9pt); <code>expand+hot</code> 层语料 → 5,410; <code>loop1 n=5124 scorecard</code> 97.89%; <code>qualbench</code> 诞生
D3 09-17	波次战	vendor 23 件翻 492 格; <code>illegal_unit</code> 108 闭环; ReDoS 修复 <code>pytest</code> 48min→3:46; <code>xlat P0</code> 封死错配通道; realn200 98.5% 真臂验收
D4 09-18	selfimp 环	常驻改进环 23 车道发车; <code>loop2</code> 97.26%/86.42%; dollar 族 leak 清零 ; <code>qualbase</code> 92.9 建档; <code>corpus_daily</code> 日更渠启动
D5 09-19	收官 + 全量	corpus_v3 八层 13,266 篇 (dev/eval 分治); 完整性审计全绿; 12 臂综合测试同日落地 (本报告主体); <code>loop3</code> 在飞

3.2 编译健康度

三条叙事线 (图 4): **fixloop** 是单一最大杠杆——09-16 接产品链当日 `union pdf` +18.9pt (70.6→89.5, 同 n180 复跑); **波次战把残面打成个位数**——vendor 波翻 492 格 fail 面、`illegal_unit` 108/108 闭环、`scorecard` 一波 89.17→97.89; **real 与 mock 打平**——`realn200 union pdf` 98.5%




图 4: 编译健康度时间线。scorecard 线为 stagerun records 在代码演进下的重评 (loop1 $n=5124 \rightarrow$ loop2 $n=5219 \rightarrow$ v3all 样本 $n=80$)；real 臂为真 LLM 翻译全链 (realn200 $\rightarrow$ e2e-v3b $n=60$ 终态)；方块为裸编译基线——注意基线自身四天涨 $\sim 19\text{pt}$ (71.7 $\rightarrow$ 90.2)：vendored 宏包资产 + tlmgr usertree 积累使工具链整体成熟，「裸引擎撑死七成」的 09-15 结论已不适用今日地板。

证明评测面非虚高，今日 e2e-v3b 终态 96.7% (7 个 pipe-fail 全被 fixloop 救回、2 格 oversize 跳过)。未达标字面只剩 M2 clean $\geq 90\%$ (今 88.75%， -1.25pt)。

3.3 解析侧：identity 守住，leak 四天内归零再现身




图 5: 解析侧演化。左：leak 命中数——dollar 族 58/57 条残留于 09-18 c2-dollar 车道清零 (核心层口径)，09-19 全量 28,904 文件上重现 76 条 (1,845,338 chunk 中 0.004%，新语料表面新案例，非回归)。右：strict identity 全测量期 $\geq 99.99\%$ (纵轴截断)。

解析侧四天稳态 (图 5)：v2 Gullet+Segmenter cutover 当日 splice 残留占位符 1524 $\rightarrow$ 0；leak 残留清一色 dollar 族，09-18 单类收口归零——但归零是在 1,955 文件核心层上，今日 8 倍体量全量复测重现 76 条命中，说明该族机制在长尾语料上未穷举，属于「已识别族的覆盖率问题」而非新机制。




图 6: 翻译侧演化。左: swe-2-medium 硬契约率——09-15 smoke 期网关不稳 (http_err 17) 压到 64.6%, 契约批 98.8%, 今日全层抽样 93.7% (新校验口径 v_err 27 条计入后更严); 右: ESA judge 均分 92.9→94.0 (swe-2-max 评审, contested 8.1%→5.5% 下降)。

3.4 翻译侧：硬契约与质量评分

3.5 评测资产与代码规模




图 7: 资产增长 (git 历史抽样, 同日口径一致): pytest 798→6,450、fixloop 规则 31→143 (16 分片)、src 72→425 文件、语料 corpus39/v2 → v3 八层 13,266 (另有 corpus_daily 日更渠 ~1,200 篇/日在库外增长)。

3.6 归因表：哪些改动搬动了哪些指标

4 2026-09-19 全量画像

本节为 corpus_v3 扩充收官 (13,266 篇) 后的首轮全量综合测试, 12 个评测臂同日落地。总表见表 5, 逐节展开关键分布。

4.1 全链漏斗：stagerun DAG

五阶段批量驱动对 80 篇跨层样本的实测漏斗 (图 8): ingest 80 → parse 79 ok (1 reject) → xlat mock 臂 76 ok + 3 partial → compile zh 臂 61 clean + 13 partial + 5 fail + 1 skip → fixloop 在 21 格上动作 (fail→clean 5、partial→clean 5、partial 保持 8、clean 复核 3)。union 终

表 4: 改动 → 指标位移归因 (commit 级, 摘自台账与各波报告)

日期	改动 (commit)	指标位移
09-14	8 库横评 + miniscanner spike	主解析器路线定案 (陷阱 32/32, identity 259/259)
09-15	corpus_v3 core+booster + 双引擎基线	基线口径建立 (union pdf 71.7%/clean 39.4%, n180)
09-15	fixloop yaml 引擎落地 (179f7e5b)	25 条规则移植, 修复臂诞生
09-16	fixloop 接产品链 (3d5de8f7)	union pdf 70.6→89.5% (+18.9pt, 同口径复跑)
09-16	v2 Gullet+Segmenter 默认切换 (f4616838)	splice 残留占位符 1524→0 (cutover 硬门)
09-16	argspec.json 入包 (401e9bbf)	1820 条宏参规格零装载 GAP 闭合
09-16	perf-tail 五修	latex parse 长尾 -48% (51476→26723ms), identity 零回退
09-16	stagerun loop1 全 DAG (n=5124)	scorecard 97.89%/84.99%; fixloop rescue 84.0%
09-17	vendored_fetch + vendor 23 件 (a90978ab)	绝版宏包缺件面 492 格 fail→73.2% clean, clean +101 格
09-17	illegal_unit 段修波 (d2c377bd)	108/108 闭环零回归, clean 84.76→85.03%
09-17	ReDoS 原子组修复 (746237fd)	held6 卡死 30min+→0.1s; pytest 全量 48min→3:46
09-17	xlat 非锚定 [n] parse 撤除 (164a9e0f, P0)	译文静默错配通道封死, 同批核销 4 P1
09-17	realn200 真臂验收 (f2847c33)	union pdf 197/200=98.5%, 与 mock 打平
09-18	c2-dollar 车道收口	leak 57→0/136,049 chunks (核心层口径单类清零)
09-18	gate_scorecard schema v3	loop1 复跑 97.89/84.99 分毫不差——评测器自证稳定
09-18	qualbase esa2 (n=1200)	质量基线建档 mean 92.9 [92.4,93.3], contested 8.1%
09-18	loop2 冻结快照 (n=5219)	scorecard 97.26%/86.42% (clean +1.43pt)
09-19	corpus 8 层扩容 (13c603cf)	语料 5232→13,266, EVAL_ONLY 治理落地
09-19	全量综合测试 (本报告)	12 臂同日落地; 基线地板升至 90.2%; stagerun 98.75%/88.75%

表 5: 2026-09-19 综合测试逐臂指标总表

臂	规模	核心指标	门槛对比
完整性审计	13,266 cells	sha256 13,266/13,266, 0 dup, 0 missing; 13 stub 为 B07 有意构造	EVAL_ONLY 生效
parsebench	13,253 篇 / 28,904 .tex	parse ok 100.0% ; identity 99.99% ; leak 0.004% (76/1,845,338) ; expand footprint strict 28105/norm 259/div 539; flatten 93.7%	identity/leak PASS; dead ph=3 FAIL; flatten FAIL
compilebench base	500 格 ×2	xelatex 56.3% clean/80.3% pdf; tectonic 38.6%/62.4%; 联合 pdf 90.4%	—
compilebench zh	500 格	xelatex 72.4%/85.4% (+16pt); tectonic 45.7%/59.8%	—
fixloop (v2 40)	80 格	xelatex 34 FAIL→ 25 救回 74% ; tectonic 1/16 (eps_route 主导)	—
alignbench	812 对	门全过; 765/812 对 named-dests= 0, 真实覆盖 42 对 (retention p50 1.0)	覆盖不足
e2e_mock	corpus39	pipe-xel 33/39 clean vs base-xel 19/39; 引入回归 3	—
e2e_real	n=24+60	58/58 翻译; chunk ok 6053/7580; splice 残留 0 ; pipe-xel clean 43/fail 7; fixloop 再救 13; 0 引入回归	—
xlatbench	271 样本	hard_ok 93.7% ; http_err 0; 延迟 p50 4.2s/p95 29.7s	—
qualbench	324 篇/1937 chunk	judge 均分 94.0 , median 95; ≥90 占 90.6%; contested 5.5%; critical 1	—
gullet	200 文档	199/200 展开成功; median 39.6ms/19 steps	—
stagerun DAG	80 篇跨层	union pdf 79/80=98.75% ; clean 71/80=88.75%	M2 pdf 门 PASS

态 **clean 71 + partial 8 = pdf 79/80 (98.75%)**, 过 M2 union-pdf ≥ 90% 门; clean 88.75% 距 90% 门差 1.25pt。同格对照臂 base (裸编译 50 clean + 19 partial + 10 fail) 给出归因锚点: 管线 +fixloop 相对裸编译 **pdf +10 格 (69→79)**、**clean +21 格 (50→71)**。




图 8: stagerun 五阶段漏斗与同格对照 (80 篇跨层样本, xlat 为 mock 上游)。左: 主流管线 zh 臂逐段存活数; 右: 同一 80 格上 base 裸编译 vs zh+fixloop union 终态——管线相对裸编译 pdf +10 格、clean +21 格 (fixloop 救回 fail 5 格全升 clean、partial 5 格升 clean)。

4.2 翻译质量: qualbench ESA 评分

swe-2-medium 译文对 324 篇论文 1,937 个 chunk 的 LLM-judge 评分 (judge=swe-2-max, 二裁 swe-2-high, contested 5.5% 触发二裁): mean 94.0 / median 95, ≥90 分占 90.6%, critical 级缺陷仅 1 例 (non-translation)。分数段与文类分布见图 9: section_title 最高 (96.9), caption 93.2, para 92.2——长散文段仍是质量洼地。




图 9: qualbench 评分分布 (左: 分数段; 右: per-kind 均分)。1,756/1,937 chunk ≥ 90 ; para 类是主要拉低项 (flag 榜: term_inconsistency 229、grammar 197、mistranslation 132、hallucinated_content 66)。

4.3 编译臂: baseline vs zh 条件

500 格抽样双引擎对照 (图 10): zh 条件 (产品链 normalize + ctex 注入后编译) 反而比裸编译高 16pt clean——normalize 顺带修复了源文件的编码/格式缺陷。tectonic 在 zh 臂 clean 升而 pdf 略降, EPS 图源是其死穴 (见 §5)。




图 10: compilebench 500 格: baseline vs zh 条件。zh 臂 xelatex clean +16.1pt——normalize 修复了源级缺陷; union pdf 90.4% (双引擎取优)。

4.4 翻译硬契约: xlatbench

271 个抽样上下文对 swe-2-medium 的硬契约测试: hard_ok 254/271=93.7%, http_err 0。延迟 p50 4.2s / p90 16.2s / p95 29.7s / max 104.4s——bg 批量档 in-gate 排队在长尾可见。token 经济: tok_in 77.4k / tok_out 40.8k (均 285/150 per chunk), reasoning 均 93 tok, prompt 缓存命中 0% (抽样源分散)。per-kind 契约率: stress 4/4、para 64/67、caption 62/67、item 61/66、footnote 58/60——footnote/item 类是短板。失败类: cs_dropped×8、ph_miss×5、validator×3、ord_hard×1; ord_soft 78 条软序告警 (不改契约, 但提示换序倾向)。

4.5 e2e 全链: mock 与 real 双臂

e2e_mock (corpus39): pipe-xel 33/39 clean vs base-xel 19/39——管线净正, 翻译 +splice 步骤不损反而增益 (normalize 修复); 3 格引入回归。e2e_real n=60: 58/58 翻译完成, chunk ok 6053/7580 (partial 43/fault 8), splice 残留占位符 0 (PASS), pipe-xel clean 43/fail 7/partial 6, fixloop 再救 13 格, **0 管线引入回归**。编译失败类: missing_file×7、missing_graphic×3、killed_by_signal×3、driver_fatal×3——以语料源缺资产为主。

5 失败归因图谱

5.1 解析侧失败面

全量 28,904 文件仅 1 个 parse 错误 (语料源怪癖: 伪装成 .tex 的 tar 包) 与 1 个 identity diverged 文件——硬失败面已枯竭, 残面转移为 warning 谱 (不挡 parse 但值得跟踪的形态): stray_end 3,007、missing_input 2,757、unpaired_dollar 383、expand_tail_dropped 313、unclosed_env 223、def_parse_fail 140、cite_range_key 62、env_mismatch 27 等。leak 76 条命中构成 dollar×75 + ref_family×1——dollar 族长尾未穷举 (演化史见图 5)。

5.2 编译侧失败类

e2e_real n=60 的编译失败归因 (图 11 左): missing_file×7 与 missing_graphic×3 合计过半——语料源自身缺资产 (arXiv e-print 打包不全), 非管线引入; killed_by_signal×3 为超时/资源类; driver_fatal×3 为引擎级崩溃。

compilebench n=500 裸编译首错归因 (fixloop F 命名): xelatex 侧 **missing_file×94** 居首 (代表 psfig.sty——古早宏包缺件) > other×48 > driver_fatal×13; tectonic 侧 **ps_image×142** 一家独大 (EPS 图源)。路由收益有实证: eps/pstricks→xel 优先带 162 篇, xel 出 pdf 90/24/47 vs tec 4/22/135; latex209_suspect 带 65 篇呈反向互补 (xel FAIL 43 vs tec pdf~ 36——古文在 tectonic 下更易出带瑕疵 PDF), non_utf8 带 37 篇。学科面难度分层明显: cs 最易 (xel pdf 83/86)、math 次之 (79/87)、astro-ph 最难 (41/64)。

fixloop 救回矩阵 (corpus_v2 40 篇对照): xelatex 34 个 FAIL 格救回 25 (74%), 主力规则为 install_file (14 触发, 8 格出 pdf)、install_tfm (12 触发, 7 格)、static_precheck (40 格全触发); 装包榜首位 subfigure.sty×10、revtex4.cls×9。tectonic 臂仅救 1/16——**eps_route reject 是结构性死穴** (11 格全拒): EPS 图源在 tectonic/xdvipdfmx 通路无解, 唯一出路是路由 xelatex。另有 latex209_reject 闸拦下 LaTeX2.09 古文 8 格 (该类论文需 209→2e 重写通道, 非装包可救)。本批 stagerun 中 fixloop 动作谱更轻量: 21 格上触发 tar_blob_extract、subfile_docclass_strip、static_precheck 标准三件套全命中, 外加 missing_char_fix、vendored_fetch、legacy_pkg_shim 等 10 条各 1-4 次。

5.3 翻译侧失败类

xlatbench 失败类分布 (图 11 右, 17 个 hard_fail 全归因): **cs_dropped×8** 居首——控制序列在译文中丢失, 且高度集中为脆弱间距命令 (\ 、\、~ 被中文熔合吞掉, 占 8 中 7 条);

ph_miss×5（占位符未还原，其中一格连丢 CMD_77-CMD_85 九个占位符——单 chunk 级联性丢失而非均匀散布）、comment_eof×2（译文尾段注释未终结吞掉下一行字面量，可致 splice 后 runaway）、validator×3、ord_hard×1；另 ord_soft 78 条为不破契约的 chunk 顺序软告警（合法中文换序的常见形态）。

qualbench flag 榜 (1,937 judged chunk, severity 分层): term_inconsistency 229、grammar 197、mistranslation 132、fluency_register 99、hallucinated_content 66、untranslated_spans 37、over_translation 23、placeholder_broken 8。按 category×severity 看结构: terminology 263 条 (231 minor/32 major) 是最大缺陷类但多为轻症；**convention-do_not_translate 25 条中 23 条 major**——不该译的内容被译（参考文献/命令名），是少量但系统性的协议违例；critical 仅 non-translation 1 例。




图 11: 失败类分布。左: e2e_real n=60 编译失败归因——语料源缺资产主导；右: xlatbench 271 样本翻译失败/告警类——cs_dropped 为头号硬失败。

5.4 门槛 FAIL 与已知缺口

1. **dead protect ph=3** (parsebench): 死占位符残留 3 例, 门为 0——唯一 gate FAIL 项, 值小但需逐例归因。全量 28,904 文件中唯一 parse 错误为「伪装成 .tex 的 tar 包」(2211.00110 内 affinity_mat.tex)——语料源怪癖而非解析器缺陷; identity 唯一 diverged 文件同待逐例归因。
2. **flatten 93.7% < 99%**: 已知 errata——多层语料中附属 .tex (孤儿文件, 不被主文档引用) 不进 flatten 面的占比, 口径而非缺陷。
3. **alignbench 覆盖薄**: 812 对中 765 对 named-dests 为零——保留率指标实际只在 42 个 hyperref 对上有意义, 指标口径需复核 (分母该是所有对还是仅 hyperref 对)。
4. **tectonic 短板**: eps_route 无解 + biblatex↔biber 版本错配——EPS/bib 论文在 tectonic 下是先天缺省, 路由层应前置判走 xelatex。
5. **cs_dropped 归因待定**: prompt 侧约束不足 vs 网关侧截断, 需在 xlatbench 加对照实验分辨。
6. **stagerun scorecard 口径**: records 混存首轮欠采的 stale skip 行会污染读数 (本批 989 条把 union pdf 冲成 7.4% 假象; 按 ingest 样本口径重算 98.75%)——工具层待加 --since/样本过滤参数。
7. **未测臂**: translators_bench、validbench (B6)、nightwatch、rundiff、trriage、stage_timing、

wave、status_panel——监控/辅助工具为主，本轮未覆盖。

A 口径与数据说明

A.1 统计口径纪律

- 每个数字标注规模 n 与样本框；不同 n /口径的读数不连成同一演化线（图注注明口径切换点）。
- scorecard 读数一律按 ingest 样本集过滤后计算——stagerun records 为 append-only，跨轮重跑会残留 stale 行，原始行计数会把未参与样本的 skip 计入分母。
- clean/pdf 为编译终态分级：clean = 无 warning 出 PDF；pdf~ = 带可接受瑕疵出 PDF（acceptable/best_effort/dirty 三档）；union pdf = clean + pdf~。
- 延迟为网关端到端秒；bg 批量档 in-gate 排队 ~120s，拥塞期 p95 会被队列时间放大，读数与空闲档不可比。
- qualbench 评分由 LLM judge（swe-2-max）产出，contested 判例经第二 judge（swe-2-high）仲裁；judge 自身偏差未做人工标定，分数应读作相对分布而非绝对正确率。

A.2 随档清单与原始产物索引

本报告自包含：所有图表由随档 data/ 原始数据生成，引用源文档的时点快照在随档 refs/，不依赖本目录以外的路径。

目录	内容
data/	五条时间线 CSV (scorecard / parse / corpus / rules-tests / qual-xlat); arms_history.csv 377 行评测流水（含各轮 run 目录名、样本量、头条读数）; commits.json 1,648 commit 全录; milestones.md D0-D5 大事记
refs/	10-benchmark-suite.md（评测器规格：七臂定义/门槛）；09-benchmark-corpus.md（语料规格：层构造/治理）；PROTOCOL.md（逐库横评协议）；TIERS.md（验证分层契约 L0-L3）；corpus_v3-MANIFEST.md（层语义/EVAL_ONLY）；mechanisms.jsonl（机制台账快照 263 条）；00-grand-comparison.md（8 库横评，D0 定案证据）；bench-metrics-corpusv3-2026-09-19.md（本批 Markdown 总表）；review-2026-09-18.md + metrics-timeline.svg + assets-growth.svg(上一期复盘);overseer-selfimp-snapshot.md（车队台账 09-19 时点快照）

各臂原始评测产物（编译工作区、译文 jsonl、PDF 中间件）为大体量文件不入档；溯源时按 data/arms_history.csv 的 run 目录名在评测产物存档区查找对应轮次。

A.3 过程事故记录（评测工具链教训）

本批测试记录的 harness 层教训，供后续批次回避：xlatbench 的 `manifest.parent` 必须等于语料根（跨目录 manifest 会 cell 解析失败）；`--per-kind` 是全局限额非分层配额；pgrep 监控须用 `[x]pattern` 括号形防自匹配；compilebench `--gen-sample` 为分段设计（采样后即返回，编译需无参二次调用）；e2e 同 `--tag` 冻结样本，重抽样须换 `tag+seed`；gullet `--out` 续跑保留 stale err 行须换新目录；stagerun 下游阶段须显式传 `--ids` 防跨层欠采；多会话共仓 commit 须走私有 `GIT_INDEX_FILE`（共享 index 有 sweep/reset 竞争窗）。